FACULTAD DE
ESTUDIOS ESTADÍSTICOS

GRADO EN ESTADÍSTICA APLICADA

Curso 2024/2025

Trabajo de Fin de Grado

TÍTULO:

PERFILES SOCIODEMOGRÁFICOS Y PERCEPCIÓN DEL CONFLICTO: UN ENFOQUE DESDE LA ESTADÍSTICA APLICADA

ALUMNO: Tania Tutor García

Tutor: Fernando Pérez Contreras

Mayo 2025

UNIVERSIDAD COMPLUTENSE
MADRID

UNIVERSIDAD
COMPLUTENSE
MADRID

Declaración Responsable sobre Autoría y Uso Ético de Herramientas de Inteligencia Artificial (IA)

Yo, TUTOR GARCÍA TANIA

Con DNI/NIE/PASAPORTE:

72894702C

declaro de manera responsable que el/la presente:

- ☐ Trabajo de Fin de Grado (TFG)
- ☐ Trabajo de Fin de Máster (TFM)
- ☐ Tesis Doctoral

Titulado/a:
PERFILES SOCIODEMOGRÁFICOS Y PERCEPCIÓN DEL CONFLICTO: UN ENFOQUE DESDE LA ESTADÍSTICA APLICADA

es el resultado de mi trabajo intelectual personal y creativo, y ha sido elaborado de acuerdo con los principios éticos y las normas de integridad vigentes en la comunidad académica y, más específicamente, en la Universidad Complutense de Madrid.

Soy, pues, autor del material aquí incluido y, cuando no ha sido así y he tomado el material de otra fuente, lo he citado o bien he declarado su procedencia de forma clara -incluidas, en su caso, herramientas de inteligencia artificial-. Las ideas y aportaciones principales incluidas en este trabajo, y que acreditan la adquisición de competencias, son mías y no proceden de otras fuentes o han sido reescritas usando material de otras fuentes.

Asimismo, aseguro que los datos y recursos utilizados son legítimos, verificables y han sido obtenidos de fuentes confiables y autorizadas. Además, he tomado medidas para garantizar la confidencialidad y privacidad de los datos utilizados, evitando cualquier tipo de sesgo o discriminación injusta en el tratamiento de la información.

En Madrid a 04/06/2025

Índice

RESUMEN 4
ABSTRACT 4
1. INTRODUCCIÓN 6
2. OBJETIVOS 8
3. DESCRIPCIÓN DEL CONJUNTO DE DATOS 9
4. DEPURACIÓN DE DATOS 10
4.1. Limpieza y preparación de los datos 11
4.2. Reducción del número de clases 12
4.3. Datos atípicos 13
5. TRATAMIENTO DE LOS DATOS 13
5.1. Creación y selección de la variable respuesta 13
5.2. Variables Explicativas 15
5.2.1. Variables numéricas 15
5.2.2. Variables categóricas 16
6. MARCO TEORICO 18
6.1. Regresión Logística 18
6.2. Random Forest 20
6.3. Arboles de decisión 22
6.4. Redes neuronales 25
7. AJUSTE DE LOS MODELOS Y SELECCIÓN DEL ÓPTIMO 28
7.1. Ficheros de entrenamiento y validación 28
7.2. Metodología 29
7.3. Regresión Logística 30
7.4. Random Forest 36
7.5. Redes neuronales 39
7.6. Selección del modelo óptimo 43
8. CONCLUSIONES 44
9. BIBLIOGRAFÍA 45
10. ANEXOS 46
10.1. Análisis descriptivo 46
10.2. Código R 51

RESUMEN

El presente estudio abordará el análisis de cómo varían las percepciones de los ciudadanos sobre los principales problemas del mundo como el cambio climático, las guerras o la desigualdad en función de sus características sociodemográficas, nivel educativo, ideología y otras actitudes sociales.

Para ello, se hará uso de datos obtenidos de la base de datos el Estudio 3486 del Centro de Investigaciones Sociológicas (CIS), titulado *"Encuesta sobre Tendencias Sociales (IV)"*. Esta encuesta recoge información detallada sobre percepciones, actitudes y características sociodemográficas de la población española.

La metodología para llevar a cabo el trabajo se basará en diferentes técnicas estadísticas como los árboles de decisiones y Regresión Multinomial sin olvidarnos de la depuración de nuestra base de datos y tratamiento de las variables correspondientes.

ABSTRACT

This study will analyze how citizens' perceptions of major global issues, such as climate change, war, and inequality, vary depending on their sociodemographic characteristics, educational level, ideology, and other social attitudes.

To this end, we will use data obtained from the Center for Sociological Research (CIS) Study 3486 database, entitled "Survey on Social Trends (IV)." This survey collects detailed information on the perceptions, attitudes, and sociodemographic characteristics of the Spanish population.

The methodology for carrying out this study will be based on various statistical techniques, such as decision trees and multinomial regression, while also including the purification of our database and the processing of the corresponding variables.

1. INTRODUCCIÓN

En los últimos años, hemos atravesado una etapa marcada por importantes cambios sociales, económicos y políticos. Factores importantes como el aumento del coste de vida, la crisis de la vivienda, el desempleo juvenil, la sostenibilidad de los servicios públicos o los efectos de la pandemia de COVID-19 junto con las tensiones de las guerras han generado nuevas preocupaciones ciudadanas a nivel local.

España atraviesa en la actualidad un escenario social complejo, caracterizado por el impacto acumulado de diversas crisis recientes. La ciudadanía expresa crecientes preocupaciones además de existir marcadas diferencias territoriales entre comunidades autónomas y entre municipios de distinto tamaño. La situación se complica más por la diversidad de perfiles sociales que conviven en el país. Factores como el nivel educativo, la edad, el estatus económico, la orientación ideológica o la pertenencia a determinados territorios pueden influir notablemente en la manera en que los ciudadanos interpretan los problemas de su entorno.

Todos estos cambios son los que me han llevado a plantear este estudio, ya que son numerosas las noticias que recibimos cada día del resto del mundo y como nos afecta en nuestras vidas. Por ello, se plantea cuestiones como:

- ¿Cuáles con los problemas que los ciudadanos consideran más importantes actualmente?
- ¿Influye la ideología política en la percepción del problema?
- ¿Las personas que viven en distintas comunidades autónomas o zonas geográficas priorizan problemáticas distintas?
- ¿Influye los ingresos de una familia en la percepción de los problemas?

Para conseguir respuesta a dichas preguntas se ha planteado el siguiente trabajo en el que se parte de un conjunto de datos que proporciona información sobre cuestiones de interés público relacionadas con cambios y tendencias sociales. Estos datos son

obtenidos como un cuestionario por lo que la primera parte del trabajo estará centrada en realizar la depuración de estos y prepararlos para llevar a cabo la tarea planteada.

En el proceso de depuración de datos se llevarán a cabo tareas como tratamiento de los valores no contestados, tratamiento de datos atípicos o agrupación de variables poco representadas.

Las variables que conforman el conjunto de datos darán información de la edad, sexo, nacionalidad, ideología política y distintas cuestiones de interés público relacionadas con cambios y tendencias sociales como pueden ser intervención estatal, percepción sobre los discapacitados, confianza en los partidos políticos o cambios sociales.

Por consiguiente, se estudiarán los comportamientos de las distintas variables disponibles, analizando los estadísticos básicos para realizar una posterior selección de las posibles variables respuesta en base a los datos de que se disponen. Una vez realizado todo esto, se estará en disposición de aplicar técnicas predictivas a los datos con finalidad de obtener un modelo que permita ver cuáles serán los principales problemas del mundo dentro de 10 años.

Entre las metodologías más importantes que serán usadas destacan la Regresión Multinomial, los árboles aleatorios y arboles de decisiones.

2. OBJETIVOS

El principal objetivo de este trabajo es analizar los factores sociodemográficos y contextuales que influyen en la percepción de los principales problemas en España, utilizando técnicas estadísticas y de aprendizaje automático como puede ser la clasificación mediante Random Forest. Para ello, el objetivo se centra en la generación de un modelo estadístico que permita ver cuáles son los mayores problemas que preocupan a los ciudadanos y describir las diferencias en la percepción de problema en función de variables como edad, sexo, nivel educativo, ingresos del hogar, ideología, religión, tamaño del municipio o comunidad autónoma.

Por otro lado, este objetivo principal plantea una serie de objetivos secundarios como pueden ser:

- Procesamiento y limpieza de los datos: Para ello se generará un código para poder leer los datos con los que vamos a llevar a cabo la tarea para posteriormente realizar un análisis de los datos faltantes o atípicos.
- Análisis exploratorio de los datos: es un paso que hay que realizar en todo estudio previo a ejecutar el modelo. Es necesario conocer la naturaleza del conjunto de datos para poder trabajar con ellos
- Selección de la variable respuesta y creación o tratamiento de las variables explicativas correspondientes.
- Selección de las categorías más representativas: una variable tiene muchas categorías, para la mejora del modelo debemos quedarnos solo con las dos o tres categorías con más frecuencia.

3. DESCRIPCIÓN DEL CONJUNTO DE DATOS

A continuación, se abordará la descripción del conjunto de datos. Los datos vienen en forma de dos ficheros: 3486_num.csv y 3486_etiq.csv

El número de observaciones para cada uno de los ficheros es la misma. Por lo tanto, los pasos a seguir serán los siguientes:

1. Selección de las variables que pudieran aportar información al modelo a calcular.
2. Realizar un análisis de los valores perdidos: que son las posiciones en las que las variables sometidas a estudio no disponen de ningún valor en la base de datos. En este caso al ser una encuesta serán las preguntas no contestadas.
3. Estudio de valores atípicos: al ser una encuesta nos encontramos casos donde el ciudadano responde no sabe, son valores que pueden desvirtualizar el modelo y no deberían tenerse en cuenta a la hora de la creación de este.

Ambos ficheros contienen la misma información tienen 3800 observaciones y 219 variables, la diferencia entre ellos es:

- **3486_num.csv:** Este conjunto contiene los valores numéricos codificados correspondientes a las respuestas de los encuestados. Las variables están codificadas mediante números enteros, incluyendo tanto variables ordinales como categóricas. Estos valores son necesarios para realizar los análisis descriptivos y modelado predictivo.

- **3486_etiq.csv:** Este fichero contiene las etiquetas de texto asociadas a cada variable y categoría del fichero numérico. Es decir, traduce los códigos numéricos del fichero anterior a su interpretación textual como pregunta de la encuesta. De esta manera, permite comprender el contenido de las variables codificadas de manera legible. Este fichero es muy útil para explorar, interpretar y documentar las variables.

Como ya hemos comentado, los ficheros contienen 3800 observaciones y 219 variables, pero solo nos vamos a quedar con las variables claves relacionadas con características sociodemográficas y percepción de los problemas municipales. Dichas variables son: PROBLMUN1R, EDAD, SEXO, ESTUDIOS, ESCIDEOL, INGRESHOG, TAMUNI, CCAA, RELIGION, entre otras.

4. DEPURACIÓN DE DATOS

La depuración de datos ha sido una parte fundamental del análisis estadístico desde los inicios de la informática aplicada a las técnicas estadísticas. Antes de aplicar cualquier técnica estadística, resulta fundamental llevar a cabo un proceso riguroso de depuración de datos. Esta etapa, es esencial para garantizar que la información analizada sea fiable, consistente y libre de errores que puedan sesgar o invalidar los resultados.

Según Van den Broeck et al. (2005), *"el proceso de limpieza de datos es una etapa esencial que permite detectar anomalías, prevenir errores sistemáticos y reducir la variabilidad no explicada. Además, la calidad del análisis estadístico depende en gran medida de la calidad del conjunto de datos utilizado, siendo este un principio ampliamente aceptado en la literatura metodológica"*.

A lo largo del capítulo se abordarán herramientas esenciales para el desarrollo del trabajo:

- Agrupación en categorías variables que se encuentren poco representadas.
- Corrección de los posibles errores de escritura que pueda presentar la base de datos, tales como observaciones en mayúsculas o minúsculas o palabras mal escritas que puedan duplicar una observación
- Establecimiento de pautas que determinen qué valores perdidos deberán ser eliminados del conjunto de datos.
- Realización de un análisis exhaustivo de los valores que toman las distintas observaciones para detectar la posible presencia de datos atípicos.

4.1. Limpieza y preparación de los datos

Para asegurar la calidad del análisis, se realizó un proceso exhaustivo de limpieza y preparación de los datos extraídos. En primer lugar, se hizo una selección de variables relevantes, centradas en aspectos sociodemográficos y la percepción de los principales problemas a nivel mundial. Posteriormente, aplico una recodificación sistemática de los valores perdidos, asignando NA a códigos utilizados por el CIS para representar respuestas como “No Sabe” o “No Contesta”.

A continuación, se procedió a la conversión de variables categóricas a factores, una práctica necesaria para el análisis estadístico mediante técnicas como arboles de decisión o modelos aleatorios. Las variables transformadas fueron: PROBLMUN1R, PROBLMUN2R, PROBLMUN3R, EDAD, SEXO, ESTUDIOS, ESCIDEOL, INGRESHOG, TAMUNI, CCAA y RELIGION. Posteriormente, se eliminaron todos los registros con datos incompletos a través de un filtrado de datos y omitiendo los valores faltantes. Esto nos permite poder trabajar con un conjunto de datos consistente.

Para mejorar el rendimiento del modelo, se filtró la variable objetivo POBLMUN1R (problema principal considerado más importante entre los ciudadanos) quedándonos tan solo con las dos categorías más frecuentes, lo cual permitió mejorar significativamente el rendimiento predictivo del modelo.

Se decidió incluir en el modelo las variables PROBLMUN2R y PROBLMUN3R, correspondientes al segundo y tercer problema municipal percibido por los encuestados, bajo la hipótesis de que estas prioridades están estrechamente relacionadas con la principal (PROBLMUN1R) y, por tanto, podrían aportar valor predictivo al modelo. No obstante, se realizó un análisis cuidadoso para evitar efectos de sobreajuste o redundancia.

Estas variables me permiten construir un modelo explicativo, basado en los datos del el Estudio 3486 del Centro de Investigaciones Sociológicas (CIS), los cuales reflejan tanto los factores personales como territoriales que intervienen en la percepción ciudadana de los principales problemas mundiales.

4.2. Reducción del número de clases

Durante el proceso de modelado se detectó que la variable dependiente original PROBLMUN1R presentaba más de 30 categorías diferentes, muchas de las cuales estaban representadas por una cantidad muy baja de observaciones. Este desequilibrio provocaba que el modelo tuviera dificultades para generalizar correctamente.

Para abordar este problema, se llevó a cabo una estrategia de reducción del número de clases de la variable. Concretamente, se seleccionaron las dos categorías más frecuentes, es decir, los dos problemas más señalados por la ciudadanía en la encuesta. De esta manera, esta nueva versión de la variable permitió al modelo enfocarse en los patrones que diferencian entre las dos preocupaciones mayoritaria.

En el siguiente gráfico se presentan las 10 clases más frecuentes de la variable PROBLMUN1R, correspondiente al principal problema municipal identificado por los encuestados. Se puede observar que existe una gran concentración de respuestas en apenas dos categorías, mientras que el resto muestra frecuencias notablemente inferiores.

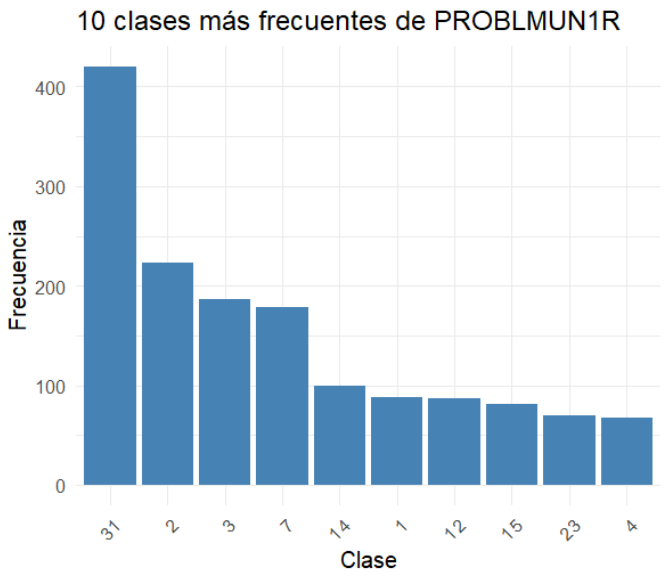

Figura 4.2

4.3. Datos atípicos

Los datos atípicos también conocidos como outliers, son observaciones que se alejan significativamente del resto de datos. Estos casos pueden surgir por errores de medición, errores en la recogida de los datos o simplemente porque representan casos extremos reales.

Se localiza en la variable ingresos del hogar valores que presentan valores extremos, pero esto puede reflejar la desigualdad económica. Por tanto, se decide no eliminar esos valores y dejar constancia para que el modelo pueda aprender d ellos.

5. TRATAMIENTO DE LOS DATOS

En este apartado se hará un pequeño resumen de como se ha ido manipulando la información de partida hasta llegar a la creación de los modelos.

5.1. Creación y selección de la variable respuesta

En primer lugar, lo que se hizo fue pasar los dos archivos que hemos comentado antes a formato xlsx, ya que estos estaban en formato csv. Una vez leídos los datos, se dio paso a comprobar que la naturaleza de cada uno de esos fuese coherente.

La elección de las variables en este estudio responde tanto a la necesidad de captar las principales preocupaciones sociales como a comprender los factores sociodemográficos, ideológicos y territoriales que las condicionan. Esta estrategia se apoya en una sólida base metodológica presente en investigaciones nacionales e internacionales.

Por ejemplo, las variables PROBLMUN1R, PROBLMUN2R y PROBLMUN3R también tienen un papel destacado en encuestas internacionales como el Eurobarómetro,

donde se pregunta de forma periódica por “los principales problemas que enfrenta el país y la UE” (European Commission, 2022), y en el International Social Survey Programme (ISSP), que recoge actitudes frente a problemas sociales recurrentes. Estas variables permiten evaluar cambios en el clima de opinión y comparar resultados por subgrupos de población. Por otro lado, también las variables CCAA y TAMUNI fueron escogidas como variables de importancia para el modelo porque permiten captar el contexto territorial, fundamental en un país con fuerte descentralización como España. Estudios como el del Instituto de Estudios Sociales Avanzados (IESA) han demostrado que algunas preocupaciones tienen un marcado componente regional o urbano/rural (IESA-CSIC, 2020). Además, la escala ideológica es clave en la explicación de la percepción diferencial de los problemas, al igual que la religión, la cual ha sido usada en otros estudios para analizar cómo las creencias religiosas influyen en la percepción de problemas ético-morales.

La variable respuesta seleccionada para el estudio representa el principal problema que, según los encuestados, afecta a su municipio. Esta elección se justifica por el objetivo principal del trabajo: analizar los factores individuales que explican la percepción de la ciudadana sobre los problemas locales de España.

Se consideraron también las variables PROBLMUN2R y PROBLMUN3R, que recogen el segundo y tercer problema más relevante según el encuestado. Sin embargo, al realizar pruebas preliminares con distintos modelos de clasificación (Random Forest y regresión logística), se observó que:

- El modelo con PROBLMUN1R como variable dependiente alcanzó un mejor resultado tras la depuración y reducción del número de clases.
- Las otras variables (PROBLMUN2R y PROBLMUN3R) generaban más ruido en la clasificación y un menor poder predictivo al no ser el problema principal percibido.

Por tanto, se concluyó que PROBLMUN1R representa de manera más directa y robusta la percepción prioritaria del ciudadano, siendo así la mejor candidata para desempeñar el rol de variable respuesta en este estudio.

Esta variable se presenta como una variable categórica multinomial con un elevado número de categorías las cuales hemos reducido a dos, como ha quedado reflejados en el apartado 4.2. De esta manera, conseguimos mejorar la precisión del modelo y reducir el riesgo de sobreajuste y de baja generalización del modelo.

Finalmente, se recodifico la variable POBLMUN1R como un factor binario, lo que permitió la mejora del rendimiento predictivo del modelo. Esta transformación nos facilita una interpretación más robusta de los resultados, manteniendo el foco del estudio en los problemas percibidos como más relevantes por los ciudadanos.

5.2. Variables Explicativas

"Una variable explicativa es aquella cuya influencia se desea estudiar sobre una determinada variable de interés, con el propósito de comprender su comportamiento o hacer predicciones." (Martín González, 2006)

Estas variables trataran de agrupar la información distribuida a lo largo de la encuesta para tratar de capturar factores tanto individuales como contextuales que puedan influir en la percepción en la percepción de los problemas municipales. Este enfoque multidimensional permite generar un modelo explicativo más sólido y realista.

5.2.1. Variables numéricas

Como su propio nombre indica, el origen de estas variables está en las variables numéricas que se disponen en el conjunto de datos. Durante el desarrollo del presente trabajo se ha optado por no modifica el contenido ni la escritura contextual de las etiquitas de las variables originales incluidas en el modelo, respetando así su formulación tal como fue diseñada para el Estudio 3486 del Centro de Investigaciones Sociológicas (CIS) en el mercado de la Encuesta sobre Tendencias Sociales.

Esta decisión responde a varios motivos:

- Rigor metodológico: las variables recogidas en la encuesta han sido formuladas y diseñadas por un equipo técnico especializado, con un diseño metodológico riguroso que garantiza su validez y fiabilidad. Alterar su codificación podría desvirtualizar el significado original o introducir sesgos interpretativos.
- Interpretabilidad sociológica: es decir, las variables utilizadas son de alta relevancia sociológica y ya están categorizadas o escaladas, según el tipo de pregunta, de forma comprensible tanto para en análisis estadístico como para la interpretación de los resultados en términos reales.

Las variables numéricas permiten capturar relaciones continuas o de escala ordinal. En este estudio se han incluido las siguientes variables numéricas:

- **EDAD:** es una variable continua que representa la edad del encuestado en años. Se utiliza para identificar posibles patrones generacionales en la percepción de problemas mundiales.
- **ESCIDEOL**: escala de ideología política (de 1 a 10), donde 1 representaba la extrema izquierda y 10 la extrema derecha. Aunque es una variable de tipo ordinal, se ha tratado como numérica dada su escala y para mantener s riqueza informativa.

5.2.2. Variables categóricas

Las variables categóricas, también conocidas como cualitativas, son aquellas que permiten clasificar los datos en grupos o categorías distintas, sin que necesariamente exista un valor numérico asociado a ellas. Este tipo de variables es fundamental en el análisis estadístico social, ya que permite estudiar comportamientos, opiniones o características que no pueden medirse directamente con números, pero que sí influyen en los resultados del modelo.

Las variables categóricas representan atributos cualitativos que pueden tener diferentes niveles o modalidades. Las variables incluidas fueron:

- **SEXO:** Categoría binaria (Hombre / Mujer). Su inclusión permite analizar diferencias en la percepción según el género.
- **ESTUDIOS:** Nivel de estudios alcanzado, recogido en forma ordinal. Se trata de una variable clave para medir el capital cultural de los individuos.
- **INGRESHOG:** Nivel de ingresos mensuales del hogar. Codificada en tramos, refleja la posición socioeconómica del encuestado y su capacidad de acceso a bienes y servicios.
- **TAMUNI**: Tamaño del municipio de residencia, clasificado en varias categorías (desde menos de 2.000 hasta más de 1.000.000 habitantes). Representa el entorno urbano o rural, que condiciona la experiencia de los problemas locales.
- **CCAA:** Comunidad Autónoma de residencia del entrevistado. Esta variable territorial permite identificar diferencias regionales en la percepción de los problemas municipales.
- **RELIGION:** Variable que indica si el encuestado se declara creyente o no, y su grado de práctica religiosa. Introducida como una dimensión sociocultural relevante.
- **PROBLMUN2R y PROBLMUN3R**: Segunda y tercera opción seleccionada por el encuestado como problemas municipales relevantes. Se incorporaron como variables explicativas adicionales para enriquecer el modelo y captar mayor profundidad informativa.

Estas variables se transformaron en factores antes de su inclusión en los modelos.

6. MARCO TEORICO

6.1. Regresión Logística

"La regresión logística es una técnica estadística utilizada para modelar la relación entre una variable dependiente dicotómica y una o más variables independientes, ya sean continuas o categóricas." (Agresti, A.,2018).

Es una técnica de análisis de datos que utiliza las matemáticas para encontrar las relaciones entre dos factores de datos. Luego, utiliza esta relación para predecir el valor de uno de esos factores basándose en el otro. Dentro del análisis de Regresión Logística se destacan dos tipos:

- La Regresión Logística Binaria: explica una característica o suceso dicotómico.
- La Regresión Logística Multinomial: explica una variable cualitativa con varias categorías.

El modelo logístico se consigue partiendo de un modelo de regresión lineal, al cual aplicando la transformación logit a la variable respuesta conseguimos ajustarlo a la forma deseada:

$$Ln\left(\frac{p}{1-p}\right) = X\beta \Rightarrow \frac{p}{1-p} = e^{x\beta} \Rightarrow p = e^{x\beta} - pe^{x\beta} \Rightarrow p + pe^{x\beta} = e^{x\beta}$$

$$\Rightarrow p\left(1 + e^{x\beta}\right) = e^{x\beta} \Rightarrow p = \frac{e^{x\beta}}{1 + e^{x\beta}} = \frac{1}{1 + e^{-x\beta}}$$

Los parámetros de este modelo se estiman por máxima verosimilitud, a partir del logaritmo de la función de verosimilitud de una distribución de Bernouilli, y la obtenemos a partir de su función de probabilidad:

$$LnL\left(y_{\{1\}}, y_{\{2\}}, \dots, y_{\{n\}}, \beta\right) = Ln \prod_{i=1}^{n} p_i^{\{y_i\}} (1 - p_i)^{\{1 - p_i\}}$$

$$= \sum_{i=1}^{n} (y_{\{i\}} Ln \frac{p_{\{i\}}}{1 - p_{\{i\}}}) + \sum_{i=1}^{n} Ln\,(1 - p_{\{i\}})$$

Una de las grandes ventajas que tiene la regresión logística con respecto a otros modelos que vamos a ver a continuación, es que se puede cuantificar la asociación existente entre las variables explicativas y la variable respuesta. Para ver la influencia de las variables explicativas se recurrirá a los Odds Ratio. Estos representan cuantas veces es más probable el éxito frente al fracaso bajo unas condiciones determinadas:

$$Odds(Y=1|X) = \frac{P(Y=1|X)}{1-P(Y=1|X)} = \frac{\frac{1}{1+e^{-X\beta}}}{1-\frac{1}{1+e^{-X\beta}}} = \frac{\frac{1}{1+e^{-X\beta}}}{\frac{e^{-X\beta}}{1+e^{-X\beta}}}$$

$$= \frac{1+e^{-X\beta}}{e^{-X\beta}(1+e^{-X\beta})} = \frac{1}{e^{-X\beta}} = e^{-X\beta}$$

Por otro lado, también se realiza una evaluación de los coeficientes individuales del modelo. Se analiza la significatividad individual de cada uno de los parámetros obtenido utilizando la prueba de Wald, que establece las siguientes hipótesis:

- $H_0: \beta_i = 0$
- $H_1: \beta_i \neq 0$

el estadístico de contraste es:

$$W = \frac{\beta_i}{SE(\beta_i)}$$

donde:

- β_i corresponde al parámetro estimado.
- $SE(\beta_i)$ hace referencia al error estándar del parámetro.

El valor del estadístico se distribuye según una distribución χ^2, la cual no podrá rechazar la hipótesis nula para valores pequeños de W, indicando así que el parámetro no sería significativo. En caso contrario, valores altos de W, se rechazará la hipótesis nula y, por tanto, se considerará que dicha variable no sería válida para explicar la variable respuesta. (Agresti, 2007)

Para concluir la explicación, definimos brevemente los distintos métodos de selección que se van a usar para tratar de encontrar el modelo logístico más apropiado:

- Método backward o eliminación progresiva. Partimos del modelo con todas las variables regresoras y vamos eliminando una a una hasta que todas las que queden sean estadísticamente significativas para el nivel fijado α.
- Método forward o introducción progresiva. Partimos del modelo con una variable regresora (la que más aporta) y vamos introduciendo variables una a una hasta que ninguna de las que quedan aporta información significativa para el nivel fijado α.
- Método stepwise o paso a paso. Es como el método forward, pero cuando una nueva variable entra en el modelo (paso forward) comprobamos si alguna de las que ya formaba parte de él debe salir (paso backward).

6.2. Random Forest

La técnica de Random Forest es una técnica de aprendizaje automático basada en la construcción de múltiples árboles de decisión, cuyos resultados se combinan para generar una predicción final. Fue propuesta por Leo Breiman (2001) como un método robusto frente al sobreajuste, y ha demostrado ser especialmente eficaz en contextos donde se requiere alta precisión y capacidad para manejar datos de diversa naturaleza.

El proceso general que suele llevar a cabo es:

- Bootstrap: Se generan múltiples subconjuntos aleatorios (con reemplazo) del conjunto de datos original.

Figura 6.2-1

- Árboles individuales: A cada subconjunto se le entrena un árbol de decisión, seleccionando aleatoriamente un subconjunto de variables en cada división (split).
- Predicción final:
  - Para clasificación: se aplica la votación mayoritaria entre todos los árboles.
  - Para regresión: se calcula la media de las predicciones de los árboles.

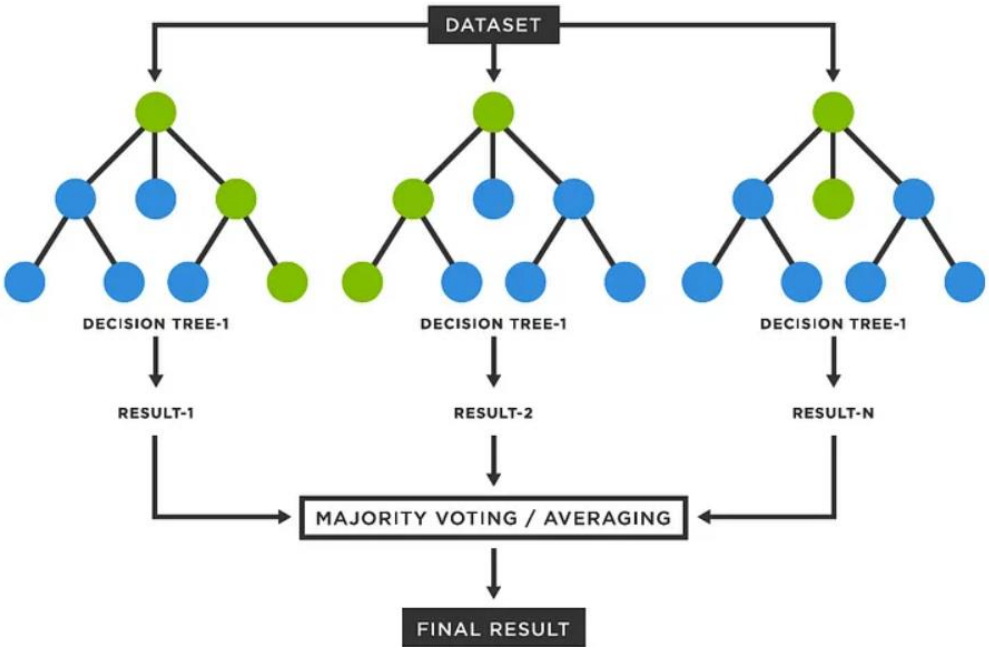

Figura 6.2-2

Este método tiene ventajas como pueden ser:

- Existen muy pocas suposiciones y por lo tanto la preparación de los datos es mínima.
- Puede manejar hasta miles de variables de entrada e identificar las más significativas. Método de reducción de dimensionalidad.
- Una de las salidas del modelo es la importancia de variables.
- Incorpora métodos efectivos para estimar valores faltantes.
- Es posible usarlo como método no supervisado (clustering) y detección de outliers.

Algunas de sus desventajas son:

- Pérdida de interpretación
- Bueno para clasificación, no tanto para regresión. Las predicciones no son de naturaleza continua.
- En regresión, no puede predecir más allá del rango de valores del conjunto de entrenamiento.
- Poco control en lo que hace el modelo (modelo caja negra para modeladores estadísticos)

6.3. Arboles de decisión

En primer lugar, hay que destacar que esta técnica de predicción no se va a utilizar de forma directa en el proyecto, sino que se va a hacer uso de otra técnica conocida como Random Forest, que se va a explicar más adelante y que está basada en la creación de múltiples árboles de decisión.

Un árbol de decisión es un modelo predictivo que utiliza una estructura en forma de árbol para representar una serie de decisiones basadas en las variables explicativas de un conjunto de datos. Su objetivo es predecir el valor de una variable dependiente (o respuesta) a partir de las respuestas a una serie de preguntas sí/no, o múltiples opciones, que dividen sucesivamente el conjunto de datos.

Visualmente, se compone de:

- Nodo raíz: el punto inicial del árbol donde se realiza la primera partición del conjunto de datos.
- Nodos internos: representan pruebas sobre variables (por ejemplo: "¿Edad > 30?").
- Hojas o nodos terminales: contienen las predicciones finales, como una categoría (en clasificación) o un valor numérico (en regresión).
- Ramas: conectan los nodos y representan el resultado de una prueba.

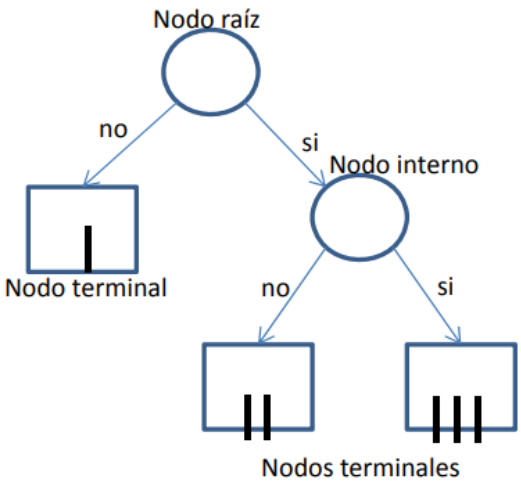

Figura 6.3-1

Los árboles de decisión dividen recursivamente el espacio de datos para construir regiones homogéneas en función de la variable objetivo. El algoritmo más conocido para construir árboles es CART (Classification and Regression Trees).

Una vez explicado el funcionamiento de un árbol, se hace necesario resolver varias cuestiones necesarias para la creación de estos. En primer lugar, debemos usar un criterio efectivo que defina cuál es la variable que se va a usar para dividir cada nodo, y cuál es el punto de corte de la condición booleana que se usará de dicha variable. Para ello, vamos a definir una medida de la bondad de la división, a la que llamaremos función de impuridad. Sea K >=2 las distintas clases de la variable respuesta que se dan lugar en las observaciones tras aplicar una regla de división:

$$i(\lambda) = \Phi(p(1 \mid \lambda), \dots, p(K \mid \lambda))$$

Siendo p (k | λ) la proporción de observaciones de la categoría k de la variable respuesta en el nodo λ, necesitamos una función ϕ que se minimice en los puntos (1, 0, ..., 0), (0, 1, ..., 0), etcétera, y que se maximice en los puntos (1/k, 1/k, ..., 1/k). De tal forma que tenemos tres opciones:

- *$\phi(p)$= min(p,1-p), (mínimo error o error de Bayes)*
- *$\phi(p)$= -p log(p) - (1-p) log(1-p), (entropía)*
- *$\phi(p)$=p(1-p), (índice de Gini)*

Algunas ventajas que tiene el árbol de decisión son:

- Es fácil de interpretar y explicar.
- No requiere normalización de los datos.
- Puede manejar tanto variables numéricas como categóricas.
- Es rápido de entrenar incluso con grandes conjuntos de datos.

Aunque el árbol de decisión es una técnica muy útil para tareas de predicción y clasificación, en este trabajo se ha optado por un modelo más avanzado y robusto: el Random Forest. La razón principal es que Random Forest es una técnica de ensamblado que supera muchas de las debilidades del árbol de decisión individual:

- En lugar de generar un solo árbol, crea múltiples árboles a partir de diferentes muestras aleatorias del conjunto de datos (bootstrapping).
- Introduce aleatoriedad en la selección de variables en cada partición, lo que disminuye la correlación entre los árboles.

- La predicción final se obtiene combinando las predicciones individuales, lo cual reduce la varianza del modelo y mejora su capacidad de generalización.

Estas características hacen que Random Forest sea menos propenso al sobreajuste y, en general, más preciso, especialmente en problemas de clasificación con múltiples variables y relaciones complejas, como es el caso del estudio realizado.

"Los árboles de decisión son intuitivos y fáciles de usar, pero su principal desventaja es que son inestables y propensos al sobreajuste. Random Forest resuelve este problema mediante el ensamblaje de múltiples árboles, ofreciendo una alternativa más precisa y robusta." (James, 2013).

6.4. Redes neuronales

Una Red Neuronal Artificial (RNA) es un modelo computacional inspirado en la estructura y el funcionamiento del cerebro humano. Está diseñada para reconocer patrones complejos y relaciones no lineales en los datos. Su arquitectura se basa en una red de nodos interconectados llamados neuronas artificiales, organizados en diferentes capas.

Las redes neuronales son una de las herramientas fundamentales del aprendizaje automático (machine learning) y, en particular, del aprendizaje profundo (deep learning) cuando tienen múltiples capas ocultas.

Una red neuronal básica se compone de:

1. **Capa de entrada (input layer)**: Contiene las variables explicativas (también llamadas *features*) del modelo. Cada neurona de esta capa representa una característica del conjunto de datos.
2. **Capas ocultas (hidden layers)**: Estas capas están compuestas por neuronas que reciben señales de la capa anterior y las procesan. Cuantas más capas

ocultas y neuronas tenga una red, mayor será su capacidad para aprender relaciones complejas, pero también será más difícil de entrenar.

3. **Capa de salida (output layer)**: Devuelve la predicción del modelo. En clasificación, puede ser una probabilidad por clase; en regresión, un valor numérico.

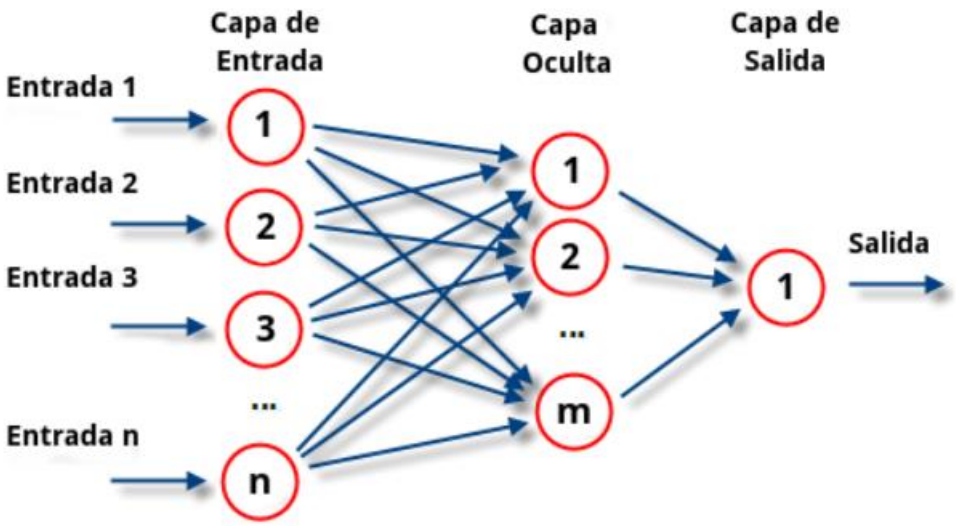

Figura 6.4-1

Además, es necesario detallar que una red puede tener más de una capa oculta, es otro de los parámetros a determinar en la arquitectura de la red, aunque normalmente redes con una capa oculta suelen ser suficientes.

Por último, se definen una serie de medidas para determinar la red neuronal óptima, las cuales permiten decidir qué conjuntos de pesos y configuraciones de la red son mejores para el problema planteado. Estas medidas son esenciales para evaluar el rendimiento del modelo y guiar el proceso de ajuste de los parámetros (tanto hiperparámetros como pesos internos). En consecuencia, contribuyen a la identificación del modelo más adecuado para realizar predicciones precisas.

Destacan entre las mismas, según Berzal (2018), las siguientes:

- Función de error: mide la diferencia entre las predicciones de la red y los valores reales. Comúnmente se utilizan funciones como la raíz del error cuadrático medio (RMSE) o la entropía cruzada, dependiendo del tipo de problema.

$$RMSE = \sqrt{\frac{1}{n}\sum\left(y_j - \hat{y}_j\right)^2}$$

- Tasa de aciertos (accuracy): indica el porcentaje de instancias correctamente clasificadas sobre el total de casos. Es una métrica habitual en problemas de clasificación.
- Precisión, recall y F1-score: especialmente útiles en contextos con clases desbalanceadas, permiten evaluar el rendimiento para cada categoría.
- Curvas ROC y AUC: proporcionan una visualización del rendimiento de un modelo binario en términos de verdaderos positivos y falsos positivos a distintos umbrales de decisión.
- Validación cruzada: técnica utilizada para asegurar que los resultados del modelo son generalizables y no dependen de una partición específica de los datos.

Estas herramientas permiten comparar diferentes configuraciones y arquitecturas de red neuronal, identificando la que ofrece el mejor compromiso entre precisión y capacidad de generalización.

Las redes neuronales son capaces de:

- Capturar relaciones no lineales y complejas entre variables.
- Aprender de grandes volúmenes de datos.
- Adaptarse a datos no estructurados (como imágenes, texto o audio).
- No es necesario hacer supuestos sobre las variables independientes ni sobre la variable respuesta.

7. AJUSTE DE LOS MODELOS Y SELECCIÓN DEL ÓPTIMO

Aquí nos adentramos ya en la búsqueda del objetivo principal del estudio. Se tratará de buscar, mediante prueba y error, el mejor modelo que se ajuste a nuestros datos, tratando de buscar el mejor resultado y con buena interpretación en los resultados finales.

7.1. Ficheros de entrenamiento y validación

A la hora de ajustar modelos de predicción es necesario fragmentar la información disponible., de modo que el modelo sea ajustado en base a unos datos y probado en base a otros distintos. Es decir, se separan los datos en entrenamiento y test de manera que esto permite evaluar la capacidad de generalización del modelo, partiendo del hecho de que cuando creamos un modelo, este se va a ajustar lo máximo posible a los datos que le ofrecemos y es posible dichos datos no sirvan para generalizar a la población. Con todo es se producirá un acierto considerable en los datos con los que hemos entrenado el modelo. En este caso la división de la información se hace en base a la variable PROBLMUN1R.

- Entrenamiento: con estos datos son con los que vamos a entrenar el modelo, es fundamental que dejemos en ellos las observaciones que realmente nos proporcionan información. En este caso, usamos todo el conjunto de datos para realizar la partición, dividimos en 80% para la parte de entrenamiento y el 20% restante para la parte test. Esto da lugar a un fichero con 515 observaciones distribuidas en base a la variable respuesta de la siguiente manera:

Categoria	Frecuencia	Porcentaje
2	179	34.76
31	336	65.24

Figura 7.1-1

Observamos que tenemos distintas proporciones para cada una de las categorías. La categoría 2 referente al problema de cambio climático y calentamiento global tiene un porcentaje bastante superior a la categoría 31 referente a las guerras. Esto es un hecho y no podemos cambiarlo. Una parte mayoritaria de la población tiene como una de las mayores preocupaciones este gran problema.

- Validación: en este caso queda un fichero de 128 observaciones. La distribución de la muestra en cuanto a la variable respuesta es la siguiente:

Categoria	Frecuencia	Porcentaje
2	44	34.38
31	84	65.62

Figura 7.1-2

En este caso nos encontramos con el mismo problema que en la parte de entrenamiento, una de las categorías esta más representada que la otra.

En ambos ficheros vamos a contar con un total de 8 variables explicativas.

7.2. Metodología

Una vez hemos explicado todos los procesos previos hasta llegar a la creación de los ficheros de entrenamiento y de validación, se da paso a exponer la metodología usada para la creación de los modelos y para la selección del que se ha considerado el mejor.

Los modelos que van a ser ajustados son: Regresión Logística, Random Forest, Árbol de decisión y redes neuronales. Para cada uno de ellos se probarán una serie de parámetros y criterios distintos a la hora de elaborarlos.

Una vez construidos los modelos es importante evaluarlos y decidir con una medida cual es óptimo.

7.3. Regresión Logística

La regresión logística ha sido seleccionada como técnica principal en este análisis por su idoneidad en el tratamiento de variables dependientes binarias. Dado que se ha reducido la variable PROBLMUN1R a sus dos categorías más frecuentes, la regresión logística permite modelar la probabilidad de que un individuo considere uno u otro problema como el más importante en su municipio, en función de variables sociodemográficas. Esta técnica, ampliamente utilizada en estudios sociales, permite interpretar de manera directa los efectos de cada variable independiente sobre la respuesta, lo que resulta especialmente útil para fines explicativos y comparativos.

Durante el desarrollo del trabajo se consideró la inclusión de las variables PROBLMUN2R y PROBLMUN3R, que representan el segundo y tercer problema municipal percibido por los encuestados. En modelos predictivos como Random Forest o KNN, su inclusión fue útil para mejorar el rendimiento al tratarse de algoritmos tolerantes a la colinealidad. Sin embargo, en modelos de regresión logística, donde el objetivo principal es la interpretación de los coeficientes y la relación entre variables independientes y dependientes, se decidió excluirlas para preservar la validez estadística y evitar redundancias lógicas.

A continuación, se va a ajustar la Regresión Logística binaria a nuestro. Cabe destacar el hecho de que todas las variables explicativas son de naturaleza de tipo factor, lo que no nos ofrece un punto a favor al tiempo de cómputo ya que es necesario considerar interacciones entre variables.

Finalmente, el modelo elegido contó con las siguientes variables, las cuales se muestran junto con la estimación del parámetro, el error estándar de dicha estimación, los Odds Ratio y su intervalo de confianza.

term	estimate	std.error	OR	IC_low	IC_high	p.value
RELIGION5	1.1255434	0.4515662	3.0818910	1.2718513	7.4678954	0.0126836
INGRESHOG6	0.9936505	0.7132339	2.7010767	0.6674519	10.9308475	0.1635708
CCAA14	0.9459851	0.6348915	2.5753490	0.7420028	8.9385410	0.1362256
INGRESHOG5	0.6878671	0.3927092	1.9894677	0.9214167	4.2955394	0.0798436
RELIGION6	0.6395428	0.4064357	1.8956141	0.8546433	4.2045058	0.1155938
RELIGION4	0.5777226	0.4054471	1.7819756	0.8049672	3.9448029	0.1541854
INGRESHOG3	0.4965570	0.3248620	1.6430545	0.8692083	3.1058473	0.1263843
SEXOMujer	0.3151503	0.2075492	1.3704653	0.9124280	2.0584366	0.1289043
CCAA12	-1.1199858	0.4125156	0.3262844	0.1453637	0.7323804	0.0066273
CCAA7	-1.1307918	0.4902689	0.3227776	0.1234747	0.8437790	0.0210842
CCAA4	-1.2665986	0.5833269	0.2817885	0.0898225	0.8840180	0.0299058

Figura 7.3-1

Una vez tenemos las variables que van a formar parte del modelo, es conveniente ver cuáles son las que más ayudan a explicar la variable respuesta. Por ejemplo, las personas de la categoría 5 de religión correspondientes a personas no creyentes o indiferentes frente a la religión, tienen 3,08 veces más probabilidad de elegir esta problemática frente a la categoría de referencia que es ser católico. Por otro lado, en el caso de los ingresos del hogar las personas que pertenecen al grupo 6: nivel de ingresos netos menores a 1.100€ tiene un efecto positivo pero el intervalo es muy amplio y el resultado estadísticamente no significativo (incluye el 1 en el intervalo de confianza), pero esto se debe al escaso número de observaciones. Además, si el ciudadano pertenece al grupo 5 o 3, ingresos netos de 1.100 a 1.800€ y de 2.701 a 3.900€, también muestra una tendencia positiva respecto a la categoría base de ingresos. Por otro lado, podemos observar que pertenecer a las comunidades autónomas Galicia, Castilla la Mancha y Baleares tienen mayor influencia en la elección del problema principal (cambio climático y calentamiento global).

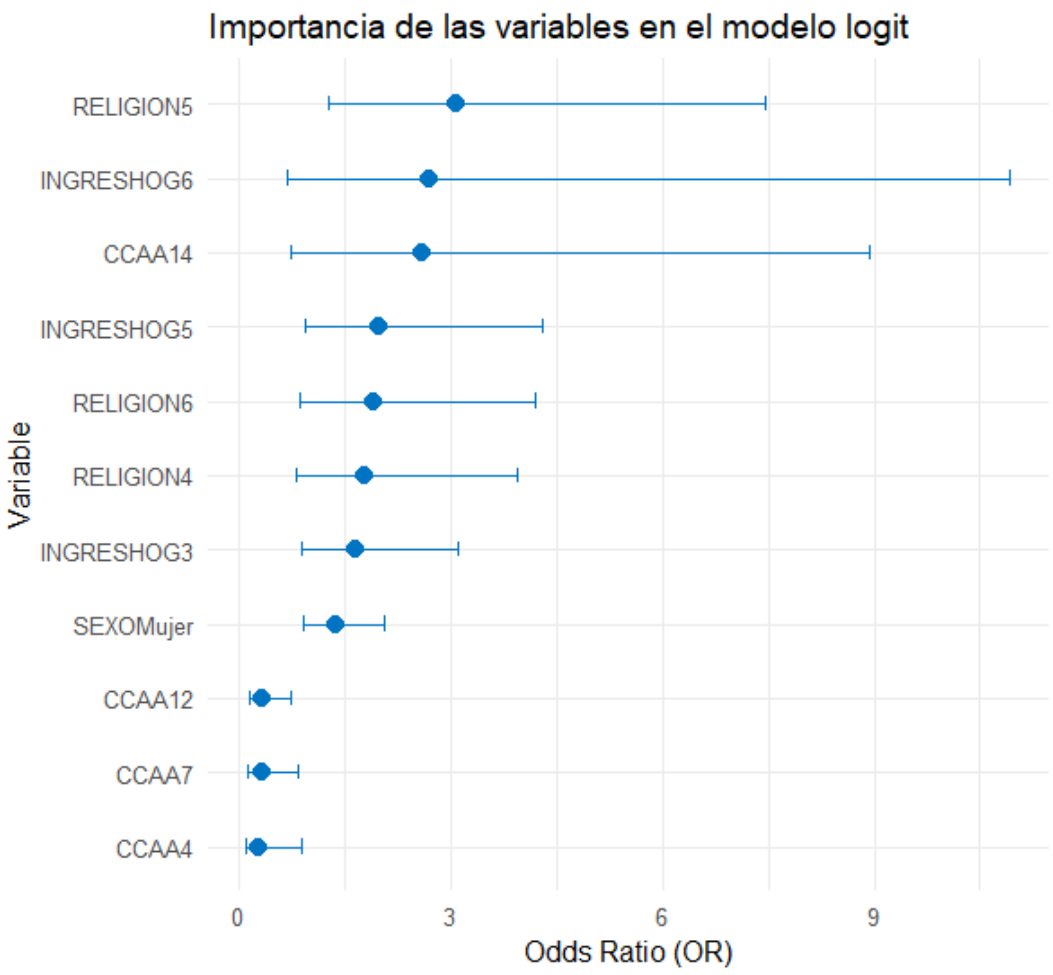

Figura 7.3-2

Por otro lado, también vamos a analizar la importancia relativa de cada variable predictora en el modelo, según el valor absoluto de su coeficiente. Cuanto mayor sea este valor, más contribuye esa variable a la predicción de la variable respuesta, aunque hay que tener en cuenta que esto no implica que esa variable sea estadísticamente significativa.

Podemos observar que la variable CCAA19 correspondiente a Melilla tiene un valor excesivamente alto en su coeficiente en comparación con el resto de los valores, esto es causado por un número muy bajo de observaciones de esta costa. También presentan coeficientes relativamente grandes ESTUDIOS2, CCAA17 y CCAA15 pero esto esta causado por lo misma razón que el caso anterior.

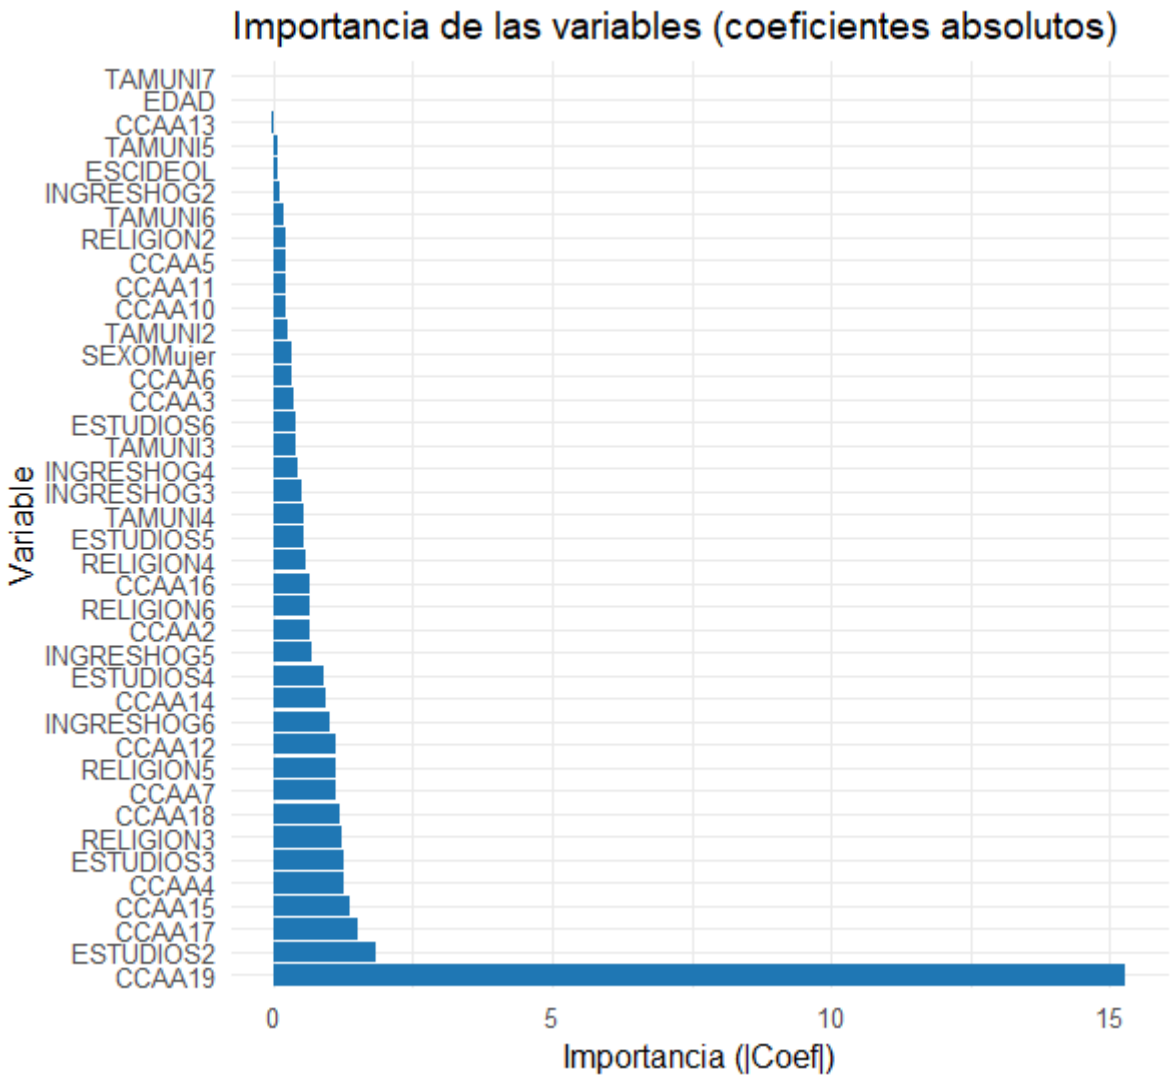

Figura 7.3-3

Por último, para ver mejor el funcionamiento del modelo, se expone la tabla de contingencia que relaciona a las predicciones con los valores observados del fichero de validación y los estadísticos correspondientes:

```
Confusion Matrix and Statistics

          Reference
Prediction  2 31
        2  13  8
        31 31 76

               Accuracy : 0.6953
                 95% CI : (0.6078, 0.7735)
    No Information Rate : 0.6562
    P-Value [Acc > NIR] : 0.202029

                  Kappa : 0.2287

 Mcnemar's Test P-Value : 0.000427

            Sensitivity : 0.2955
            Specificity : 0.9048
         Pos Pred Value : 0.6190
         Neg Pred Value : 0.7103
             Prevalence : 0.3438
         Detection Rate : 0.1016
   Detection Prevalence : 0.1641
      Balanced Accuracy : 0.6001

       'Positive' Class : 2
```

Figura 7.3-4

El modelo de regresión logística entrenado ha alcanzado una precisión del 69,53%. Esta precisión supera el No Information Rate de 65,2%, que representa la proporción de clase mayoritaria, pero podemos observar que la diferencia no es estadísticamente significativa lo que sugiere que el modelo no mejora sustancialmente respecto a la clasificación aleatoria basada en la clase más frecuente.

Por otro lado, la sensibilidad que es la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años va a ser las guerras es de 0,2955. Sin embargo, la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años va a ser el cambio climático o el calentamiento global es de 0,9048.

Además, la precisión para la clase positiva (Positive Predictive Value) es 0,6190, lo que significa que el 61,90% de las predicciones positivas fueron correctas. Por su parte, el

valor predictivo negativo es 0,7103, lo cual es aceptable. La estadística Kappa es 0,2287, indicando un acuerdo débil, pero por encima del azar entre las predicciones del modelo y los valores reales. El Balanced Accuracy (promedio entre sensibilidad y especificidad) es 0,6001, lo que refleja un rendimiento moderado, especialmente en presencia de clases desbalanceadas.

Por último, el p-valor del test de McNemar (0,000427) indica una diferencia estadísticamente significativa entre los errores tipo I y tipo II, lo que puede sugerir cierto sesgo del modelo hacia una de las clases, pero esto ya lo habíamos visto anteriormente que la categoría correspondiente a calentamiento global era un problema claramente mayoritario entre todas las categorías.

Para ver la importancia que da el modelo a cada una de las variables explicativas, vamos a aprovechar la función varImpPlot() de R para modelos Random Forest, el cual nos dará como salida dos gráficos con los que poder interpretar la capacidad discriminativa de la variable:

- MeanDecreaseAccuracy: representa cuanto disminuye la precisión (accuracy) del modelo al permutar aleatoriamente los valores de esa variable.
- MeanDecreaseGini: representa la contribución de la variable a la pureza de cada uno de los nodos, basándose en el índice de Gini, en todos los árboles del bosque.

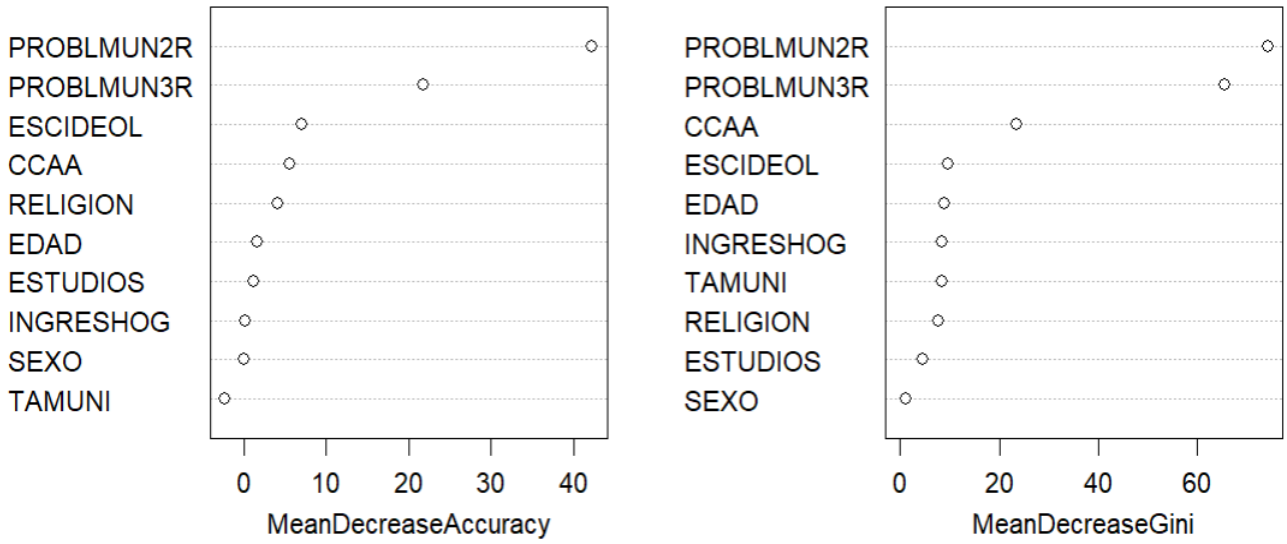

Figura 7.3-5

El grafico de importancia generado por el modelo Random Forest revela que las preguntas adicionales relacionadas con la problemática municipal son los predictores mas relevantes para identificar la principal preocupación ciudadana. Además, variables como la ideología política y la comunidad autónoma de residencia del encuestado, también aportan información significativa, lo que sugiere que la percepción de los problemas municipales esta influida tanto como por factores personales como contextuales. Otras variables sociodemográficas (edad, religión, estudios, ingresos, sexo) tienen un impacto más reducido en la predicción, pero siguen contribuyendo a mejorar la precisión del modelo.

7.4. Random Forest

En este trabajo se ha aplicado para predecir el principal problema percibido en el municipio por los ciudadanos, basándose en variables sociodemográficas. Además de su capacidad predictiva, destaca por ofrecer medidas de importancia de las variables que ayudan a interpretar el modelo.

Los distintos parámetros que se van a probar son los siguientes, llevándose a cabo todas las

posibles combinaciones de estos:

- Variables para evaluar: Número de variables que se van a escoger aleatoriamente de entre todas las disponibles cada vez que se vaya a hacer una partición de un nodo. Se escogerán entre 2, 3, 4, 5 y 6.
- Número de árboles que se van a crear: Se probará con 50, 100, 300 y 500.
- Tamaño mínimo de los nodos: Se trata del número mínimo que tiene que haber en un nodo para que se haga una partición. Se probará con 1, 5, 10, 15 y 20.

mtry	nodesize	accuracy
4	5	0.7421875
5	5	0.7421875
5	5	0.7421875
3	10	0.7343750
4	5	0.7343750
4	10	0.7343750
5	10	0.7343750
6	10	0.7343750
6	15	0.7343750
2	20	0.7343750
3	20	0.7343750
4	10	0.7343750

Figura 7.4-1

Observamos que no hay mucha diferencia entre los modelos ya que todos tienen un acierto similar a diferencia del primer caso que seria ligeramente superior. De entre ellos, nos quedamos con el primero ya que además de tener el mayor acierto tiene menor numero de variables a evaluar en cada iteración del algoritmo. El modelo de regresión logística entrenado ha alcanzado una precisión del 74,22%.

Sus características son:

- Variables que se van a evaluar: 4
- Numero de árboles: 500
- Tamaño mínimo de las particiones: 5

Por otro lado, al igual que en la regresión logística, se muestra la tabla de contingencia que relaciona a las predicciones con los valores observados del fichero de validación y los estadísticos correspondientes:

```
          Reference
Prediction  2 31
         2  11  2
        31 33 82


               Kappa : 0.2718

Mcnemar's Test P-Value : 3.959e-07

           Sensitivity : 0.25000
           Specificity : 0.97619
        Pos Pred Value : 0.84615
        Neg Pred Value : 0.71304
            Prevalence : 0.34375
        Detection Rate : 0.08594
  Detection Prevalence : 0.10156
     Balanced Accuracy : 0.61310

      'Positive' Class : 2
```

Figura 7.4-2

Podemos observar que la sensibilidad que es la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años va a ser las guerras es de 0,25. Sin embargo, la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años va a ser el cambio climático o el calentamiento global es de 0,9761.

Además, la precisión para la clase positiva (Positive Predictive Value) es 0,8461, lo que significa que el 84,61% de las predicciones positivas fueron correctas. Por su parte, el valor predictivo negativo es 0,7130, lo cual es aceptable. La estadística Kappa es 0,2718, indicando un acuerdo débil, pero por encima del azar entre las predicciones del modelo y los valores reales. El Balanced Accuracy (promedio entre sensibilidad y especificidad) es 0,6131, lo que refleja un rendimiento moderado, especialmente en presencia de clases desbalanceadas.

Por último, el p-valor del test de McNemar indica una diferencia estadísticamente significativa entre los errores tipo I y tipo II, lo que puede sugerir cierto sesgo del modelo hacia una de las clases, pero esto ya lo habíamos visto anteriormente que la categoría correspondiente a calentamiento global era un problema claramente mayoritario entre todas las categorías.

7.5. Redes neuronales

En este caso volvemos a partir de todas las variables explicativas que seleccionamos inicialmente para el modelo. Una vez tenemos las variables de las que vamos a partir, es necesario mostrar las características de los parámetros. Se realizaron varios modelos variando el número de nodos ocultos, el parámetro de regularización y el número máximo de iteraciones para encontrar la combinación que ofreciera el mejor compromiso entre precisión y complejidad del modelo. Posteriormente se evaluó la precisión del modelo sobre el conjunto de test, para cada uno de los distintos modelos generados. De esta manera, nos quedamos con el que mayor precisión tenía:

- Número de nodos ocultos: 5
- Parámetro de regularización: 0,01
- Número máximo de iteraciones: 500
- Numero de variables explicativas: 10

En una Red Neuronal, el número de parámetros a estimar es “h(k + 1) + h + 1”, siendo h el número de nodos de la capa oculta y k el número de variables explicativas o, de entrada. De tal forma, el modelo elegido va a contar con un total de 61 parámetros a estimar.

Por otro lado, al igual que en la regresión logística, se muestra la tabla de contingencia que relaciona a las predicciones con los valores observados del fichero de validación y los estadísticos correspondientes:

```
Confusion Matrix and Statistics

          Reference
Prediction  2 31
        2  20 10
        31 24 74

               Accuracy : 0.7344
                 95% CI : (0.6491, 0.8085)
    No Information Rate : 0.6562
    P-Value [Acc > NIR] : 0.03653

                  Kappa : 0.363

 Mcnemar's Test P-Value : 0.02578

            Sensitivity : 0.4545
            Specificity : 0.8810
         Pos Pred Value : 0.6667
         Neg Pred Value : 0.7551
             Prevalence : 0.3438
         Detection Rate : 0.1562
   Detection Prevalence : 0.2344
      Balanced Accuracy : 0.6677

       'Positive' Class : 2
```

Figura 7.5-1

El modelo de regresión logística entrenado ha alcanzado una precisión del 73,44%. Esta precisión supera el No Information Rate de 65,62%, que representa la proporción de clase mayoritaria, pero podemos observar que la diferencia es estadísticamente significativa lo que sugiere que el modelo mejora sustancialmente respecto a la clasificación aleatoria basada en la clase más frecuente.

Por otro lado, la sensibilidad que es la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años va a ser las guerras es de 0,4545. Sin embargo, la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes

problemas en los siguientes 10 años va a ser el cambio climático o el calentamiento global es de 0,8810.

Además, la precisión para la clase positiva (Positive Predictive Value) es 0,6667, lo que significa que el 66,67% de las predicciones positivas fueron correctas. Por su parte, el valor predictivo negativo es 0,7551, lo cual es aceptable. La estadística Kappa es 0,363, indicando un acuerdo débil, pero por encima del azar entre las predicciones del modelo y los valores reales. El Balanced Accuracy (promedio entre sensibilidad y especificidad) es 0,6677, lo que refleja un rendimiento moderado, especialmente en presencia de clases desbalanceadas.

Por último, el p-valor del test de McNemar indica una diferencia estadísticamente significativa entre los errores tipo I y tipo II, lo que puede sugerir cierto sesgo del modelo hacia una de las clases, pero esto ya lo habíamos visto anteriormente que la categoría correspondiente a calentamiento global era un problema claramente mayoritario entre todas las categorías.

A continuación, para ver la importancia de las variables, esta vez vamos a tener que hacer uso de la función de R olden() ya que esta técnica estadística dificulta la interpretación de los parámetros y por ende también la búsqueda de cuales son las variables mas influyentes.

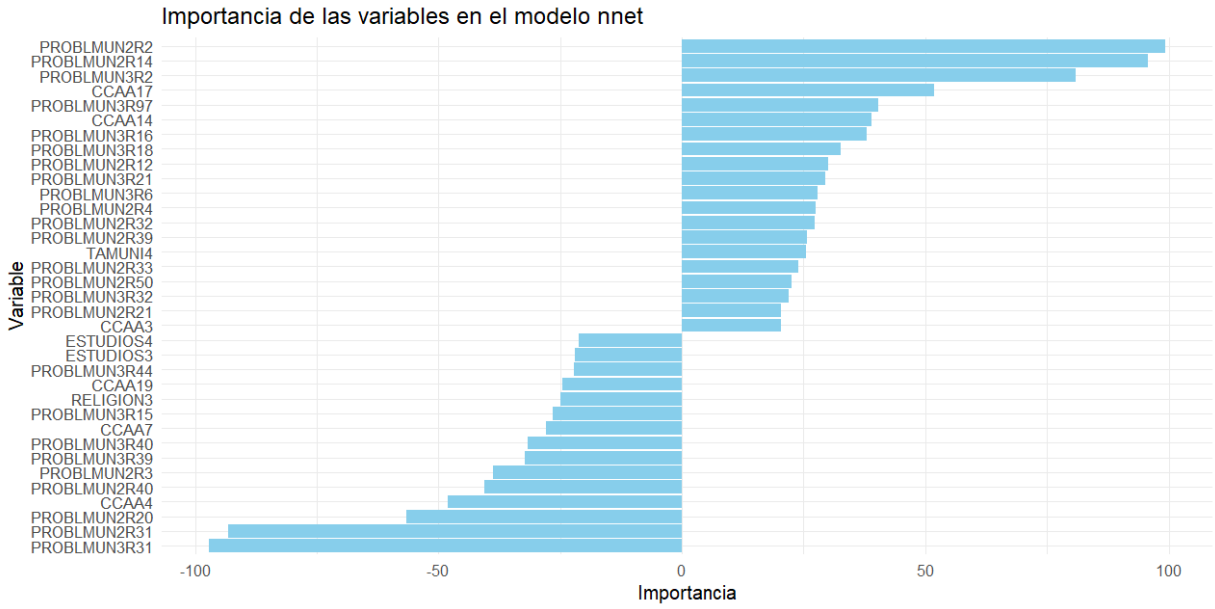

Figura 7.5-2

Variables con mayor contribución positiva

Las variables que presentan una mayor importancia positiva son:

- PROBLMUN2R2, PROBLMUN2R14 y PROBLMUN3R2: Estas variables están relacionadas con percepciones ciudadanas sobre problemas municipales. Su alta importancia sugiere que las respuestas a estas cuestiones son altamente informativas para predecir la variable objetivo. Es probable que representen preocupaciones sociales relevantes o diferenciadoras entre los grupos clasificados por el modelo.
- CCAA17 y CCAA14: Estas categorías pertenecen a la variable Comunidad Autónoma, lo que indica que la región de residencia también desempeña un papel clave en la clasificación. Esto podría reflejar diferencias regionales en la percepción o vivencia de ciertos problemas sociales.
- Otras variables como PROBLMUN3R21, PROBLMUN3R16, TAMUNI4 y PROBLMUN3R18 también aparecen con una contribución destacada, reforzando la idea de que los aspectos relacionados con el tamaño del municipio y ciertos tipos específicos de problemáticas tienen un efecto significativo en la predicción.

Estas variables deberían considerarse esenciales en futuras versiones simplificadas del modelo, dado su alto valor informativo.

Variables con importancia negativa

Por otro lado, también se identifican variables con valores negativos de importancia, entre las que destacan:

- PROBLMUN3R31, PROBLMUN2R31, PROBLMUN2R20: Estas variables no solo no aportan valor predictivo al modelo, sino que su inclusión parece introducir ruido o confusión en la predicción. Este comportamiento puede deberse a que estas preguntas contienen información redundante, poco diferenciadora o incluso contradictoria respecto al patrón general de clasificación.

- CCAA4, PROBLMUN2R23 y PROBLMUN3R40 también presentan una contribución negativa, lo que sugiere que ciertas regiones o problemáticas específicas no ayudan a discriminar entre las categorías de la variable dependiente.

La utilización de este tipo de visualizaciones no solo mejora la interpretabilidad de los modelos de tipo caja negra como las redes neuronales, sino que también facilita la toma de decisiones fundamentadas sobre la estructura final del modelo y la selección de variables más relevantes.

7.6. Selección del modelo óptimo

Una vez hemos escogido el mejor modelo de cada técnica, tenemos que decidir con cuál de ellos nos vamos a quedar para llevar a cabo las predicciones finales. A continuación, mostramos una tabla que muestra las distintas características de los modelos:

	Modelo	Accuracy	Sensibilidad	Especificidad
1	Random Forest	0.7421	0.2500	0.97619
2	Regrsión Logit	0.6953	0.2955	0.90480
3	Redes Neuronales	0.7344	0.4545	0.88100

Figura 7.6-1

En primer lugar, salta a la vista que podemos descartar a la Regresión Logística, ya que tiene una medida de bondad de ajuste considerablemente inferior a la de los otros dos modelos. De entre los dos restantes, observamos que ambos tienen un grado de acierto bastante parecido, pero destaca la diferencia de la sensibilidad que es la probabilidad estimada de clasificar correctamente a una persona que piense que uno de los grandes problemas en los siguientes 10 años, es claramente superior en el modelo de Redes Neuronales. Por tanto, se decide elegir la Red Neuronal ya que tiene una bondad de ajuste del 73,44% y una probabilidad de acierto de clasificar correctamente un encuestado es del 45,45%.

8. CONCLUSIONES

El análisis de la Encuesta de Tendencias Sociales revela una fuerte relación entre las características sociodemográficas de los individuos y su percepción sobre los principales problemas que afectan a su municipio. Variables como la edad, el nivel educativo, la clase social subjetiva y la ideología política han mostrado ser predictoras relevantes, confirmando que la percepción de los problemas sociales no es homogénea, sino que está mediada por la experiencia y la posición estructural de los encuestados.

Se han detectado diferencias significativas según la comunidad autónoma de residencia, lo que pone de manifiesto un componente territorial en la percepción del conflicto. Por ejemplo, en ciertas regiones, los problemas relacionados con la inmigración o la seguridad tienen un mayor peso, mientras que en otras predominan los problemas económicos o de vivienda. Este hallazgo refuerza la hipótesis de que los contextos regionales modelan la sensibilidad ciudadana ante distintos tipos de amenazas o problemáticas.

Uno de los objetivos del trabajo fue estudiar qué factores llevan a algunos ciudadanos a considerar las guerras como el principal problema en su entorno municipal. Los resultados indican que esta percepción es minoritaria y se asocia principalmente con personas de mayor edad, con ideologías situadas en el centro-derecha y con un bajo nivel de estudios. Además, la escasa frecuencia de esta respuesta ha dificultado la predicción efectiva mediante modelos estadísticos, subrayando la complejidad de captar percepciones excepcionales con herramientas cuantitativas tradicionales.

A pesar de la precisión aceptable en términos generales, los modelos no han conseguido predecir con éxito la pertenencia a la clase minoritaria (personas que consideran la guerra como principal problema), lo cual refleja una limitación inherente de los modelos estadísticos al trabajar con clases muy desbalanceadas.

En este sentido, el trabajo no solo cumple su objetivo, sino que también contribuye a una reflexión metodológica sobre los retos de la estadística aplicada en el estudio de

percepciones excepcionales o marginales. La imposibilidad de predecir con alta precisión un fenómeno tan específico refuerza la necesidad de combinar enfoques cuantitativos con marcos cualitativos o contextuales en estudios futuros.

La Encuesta de Tendencias Sociales del CIS se confirma como una herramienta de gran valor para el análisis de opiniones y actitudes ciudadanas. Su riqueza en variables y su representatividad permiten extraer conclusiones sólidas sobre el comportamiento social, siempre que se apliquen técnicas estadísticas adecuadas y se realice una depuración rigurosa de los datos. Este trabajo ha demostrado cómo una fuente pública de datos puede ser explotada eficazmente en investigación cuantitativa aplicada.

9. BIBLIOGRAFÍA

VAN DEN BROECK, J., ARGESEANU CUNNINGHAM, S., EECKELS, R. AND HERBST, K. Data Cleaning: Detecting, Diagnosing, and Editing Data Abnormalities. PLoS Medicine, Octubre 2005, vol. 2, no. 10.

Martínez González, M. Á., Sánchez Cantalejo, E., & Delgado Rodríguez, M. (2006). Bioestadística amigable. Elsevier España. p. 121.

Agresti, A. (2018). Statistical Methods for the Social Sciences (5th ed.). Pearson.

Agresti, A. (2007). An Introduction to Categorical Data Analysis. New Jersey: Editorial John Wiley & Sons.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer.

Breiman, L. (2001). Random Forests. Berkeley: University of California.

Minería de datos. Redes Neuronales y Árboles de decisión: Ejemplos con SAS Enterprise Miner / César Pérez López

Diseño y Análisis de Experimentos / Douglas C. Montgomery

Técnicas de Análisis Multivariante de Datos / César Pérez López

https://www.uv.es/mlejarza/actuariales/tam/arbolesdecision.pdf

https://bookdown.org/content/224878ff-81d8-4034-bd84-6fc9ff820cfc/ensambladores-random-forest-parte-i.html#random-forest

https://rpubs.com/Moki-chan/neuronal-network-parcial-breast-mama

https://sisbib.unmsm.edu.pe/bibvirtualdata/tesis/basic/flores_ml/cap3.pdf

https://www.cis.es/documents/d/cis/es3427mar_a

https://www.juntadeandalucia.es/institutodeestadisticaycartografia/dega/sites/default/files/docs/118-encuesta-social-2020-estado-alarma-metodologia.pdf

10. ANEXOS

10.1. Análisis descriptivo

A continuación, se va a realizar un análisis descriptivo de las variables finalmente usadas en el modelo. Las variables continuas han sido analizadas mediante un histograma, mientras que las categóricas se han descrito mediante tablas de frecuencias absolutas y relativas.

- Variables numéricas:

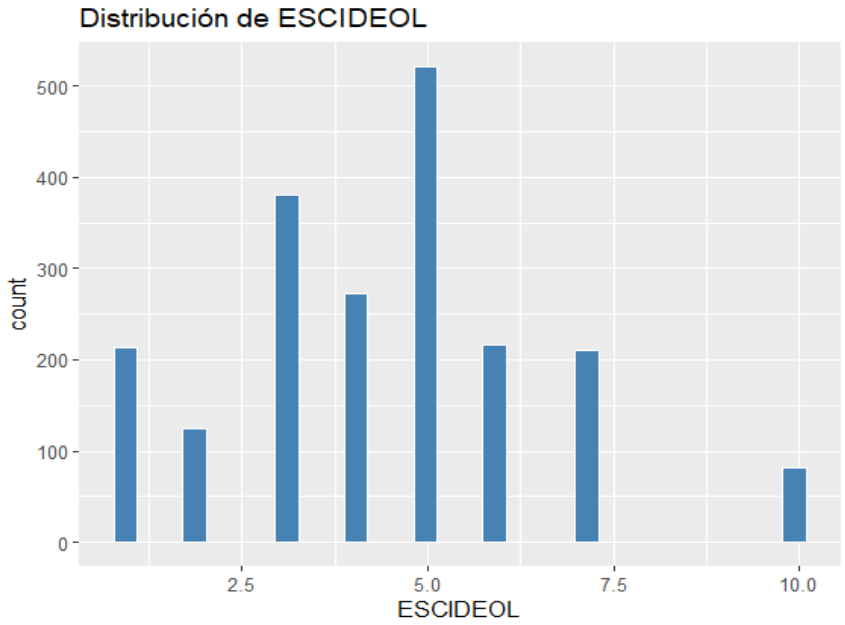

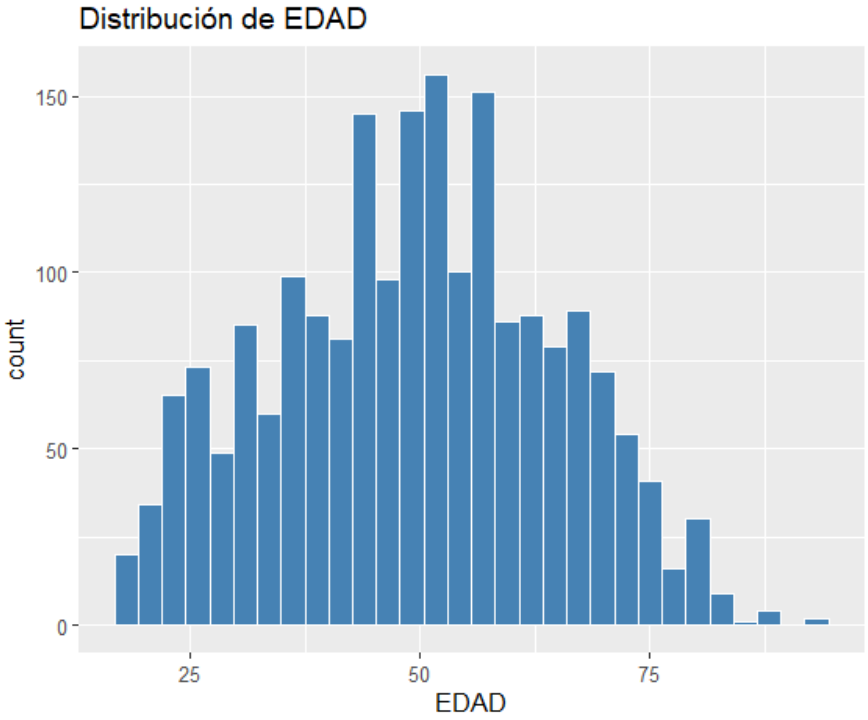


```
     EDAD          ESCIDEOL
Min.   :18.00   Min.   : 1.000
1st Qu.:38.00   1st Qu.: 3.000
Median :50.00   Median : 5.000
Mean   :49.36   Mean   : 4.399
3rd Qu.:60.00   3rd Qu.: 6.000
Max.   :93.00   Max.   :10.000
```

- Variables categóricas:

Distribución de la variable SEXO

Categoría	Frecuencia	Porcentaje
Hombre	325	50.54
Mujer	318	49.46

Distribución de la variable ESTUDIOS

Categoría	Frecuencia	Porcentaje
1	4	0.62
2	4	0.62
3	51	7.93
4	82	12.75
5	114	17.73
6	388	60.34

Distribución de la variable RELIGION

Categoría	Frecuencia	Porcentaje
1	66	10.26
2	199	30.95
3	11	1.71
4	124	19.28
5	92	14.31
6	151	23.48

Distribución de la variable INGRESHOG

Categoría	Frecuencia	Porcentaje
1	93	14.46
2	132	20.53
3	165	25.66
4	135	21.00
5	98	15.24
6	20	3.11

Distribución de la variable TAMUNI

Categoría	Frecuencia	Porcentaje
1	15	2.33
2	65	10.11
3	161	25.04
4	103	16.02
5	160	24.88
6	77	11.98
7	62	9.64

Distribución de la variable CCAA

Categoría	Frecuencia	Porcentaje
1	143	22.24
2	16	2.49
3	18	2.80
4	20	3.11
5	34	5.29
6	9	1.40
7	35	5.44
10	96	14.93
11	22	3.42
12	51	7.93
13	106	16.49
14	21	3.27
15	12	1.87
16	49	7.62
17	5	0.78
18	3	0.47
19	3	0.47

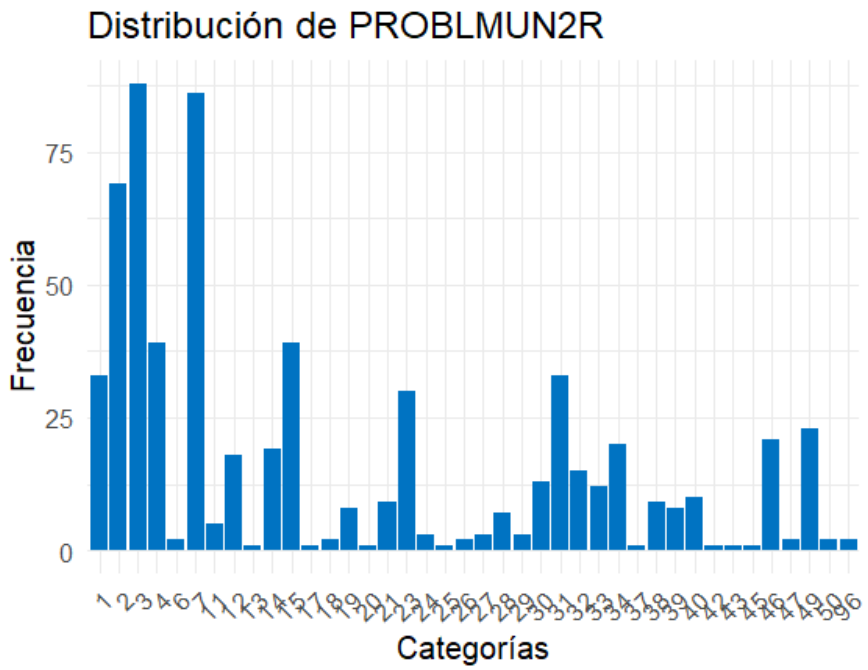

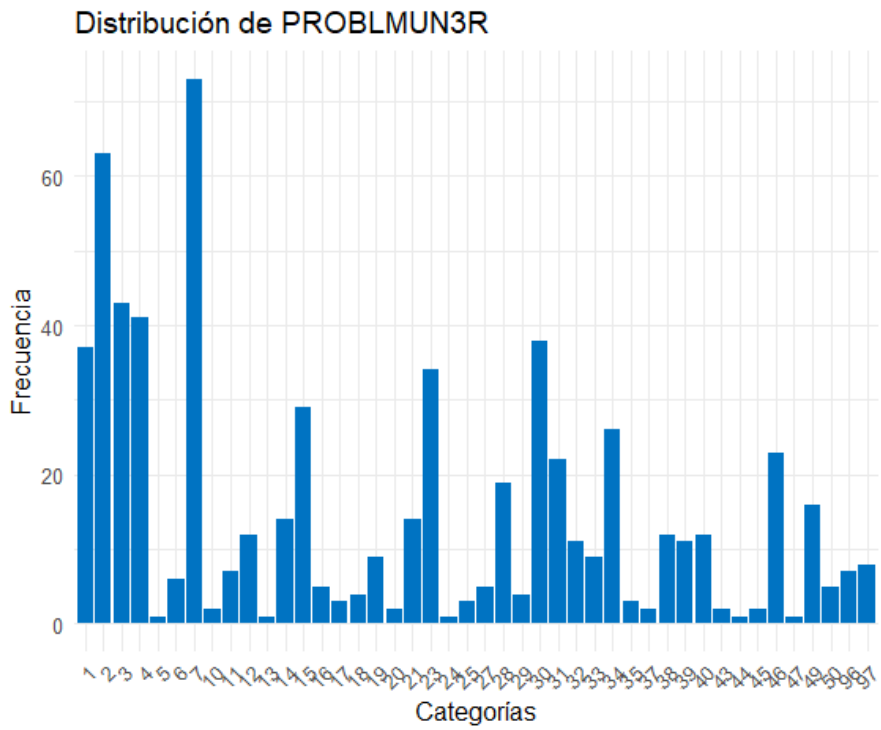

10.2. Código R

```
# Cargar datos

library(readxl)

library(dplyr)


datos <- read_excel("C:/Users/tania/OneDrive/Escritorio/TFG/ENCUESTA SOBRE
TENDENCIAS SOCIALES/3486_num.xlsx")

# Recodificación segura para NA

recode_na <- function(x) {

  x <- as.numeric(x)

  x[x %in% c(8, 9, 98, 99, 999, 9999)] <- NA

  return(x)

}
```

```
variables_interes <- c("PROBLMUN1R", "PROBLMUN2R", "PROBLMUN3R", "EDAD",
"SEXO",
                "ESTUDIOS", "ESCIDEOL", "RELIGION", "INGRESHOG", "TAMUNI", "CCAA")
variables_interes <- c("PROBLMUN1R", "PROBLMUN2R", "PROBLMUN3R", "EDAD",
"SEXO",
                "ESTUDIOS", "ESCIDEOL", "RELIGION", "INGRESHOG", "TAMUNI", "CCAA",
                "SIMBOL1R","SIMBOL2R","ECIVIL","CLASESOCIAL",
"NACIONALIDAD","INTPOL","CONFIANZA_1")


datos_limpios <- datos %>%
  select(all_of(variables_interes)) %>%
  mutate(across(everything(), recode_na)) %>%
  na.omit()


# Convertir algunas a factores
datos_limpios$SEXO <- factor(datos_limpios$SEXO, labels = c("Hombre", "Mujer"))
datos_limpios$ESTUDIOS <- factor(datos_limpios$ESTUDIOS)
#datos_limpios$ESCIDEOL <- factor(datos_limpios$ESCIDEOL)
datos_limpios$RELIGION <- factor(datos_limpios$RELIGION)
datos_limpios$PROBLMUN2R <- as.factor(datos_limpios$PROBLMUN2R)
datos_limpios$PROBLMUN3R <- as.factor(datos_limpios$PROBLMUN3R)
datos_limpios$INGRESHOG <- as.factor(datos_limpios$INGRESHOG)
datos_limpios$TAMUNI <- as.factor(datos_limpios$TAMUNI)
datos_limpios$CCAA <- as.factor(datos_limpios$CCAA)
datos_limpios$NACIONALIDAD<- as.factor(datos_limpios$NACIONALIDAD)
datos_limpios$CLASESOCIAL<- as.factor(datos_limpios$CLASESOCIAL)
datos_limpios$INTPOL<- as.factor(datos_limpios$INTPOL)
datos_limpios$CONFIANZA_1<- as.factor(datos_limpios$CONFIANZA_1)
datos_limpios$ECIVIL<- as.factor(datos_limpios$ECIVIL)
```

```
datos_limpios$SIMBOL1R<- as.factor(datos_limpios$SIMBOL1R)
datos_limpios$SIMBOL2R<- as.factor(datos_limpios$SIMBOL2R)
# Convertir variable dependiente a factor
datos_limpios$PROBLMUN1R <- as.factor(datos_limpios$PROBLMUN1R)

# Ver las 5 categorías más frecuentes
top5 <- names(sort(table(datos_limpios$PROBLMUN1R), decreasing = TRUE))[1:2]
library(dplyr)

# Filtrar para quedarnos con las 5 más frecuentes
datos_filtrados <- datos_limpios %>%
  filter(PROBLMUN1R %in% top5) %>%
  mutate(PROBLMUN1R = droplevels(PROBLMUN1R))

#librerias
library(randomForest)
library(caret)
set.seed(13656545)
set.seed(13656549)# esta
## PARTICIÓN DE DATOS ##
trainIndex <- createDataPartition(datos_filtrados$PROBLMUN1R, p = 0.8, list = FALSE)

# Dividir correctamente
datos_train <- datos_filtrados[trainIndex, ]
datos_test  <- datos_filtrados[-trainIndex, ]

##########################################################################
#########################################
```

```
                ################# REGRESIÓN LOGÍSTICA
#########################

#######################################################################
##########################################

library(MASS)     # Para stepAIC

#regvacia<- glm(PROBLMUN1R~1 ,data=datos_train, family = binomial)

#modelo_full <- glm(PROBLMUN1R ~ EDAD + SEXO + ESTUDIOS + ESCIDEOL +
INGRESHOG + TAMUNI + CCAA + RELIGION, data = datos_train, family = binomial)

#regforw<-step(regvacia, scope = list(lower=regvacia, upper=modelo_full),direction =
"both"); summary(regforw)


# Aplicar selección stepwise hacia atrás basada en AIC

#modelo_step <- stepAIC(modelo_full, direction = "both", trace = FALSE)


# Resumen del modelo

#summary(modelo_step)


# Predicciones en conjunto de prueba

#probabilidades <- predict(modelo_step, newdata = datos_test, type = "response")

#predicciones <- ifelse(probabilidades > 0.5, levels(datos_train$PROBLMUN1R)[2],
levels(datos_train$PROBLMUN1R)[1])

#predicciones <- factor(predicciones, levels = levels(datos_train$PROBLMUN1R))


# Matriz de confusión y precisión

#confusion <- confusionMatrix(predicciones, datos_test$PROBLMUN1R)

#print(confusion)


modelo_logit=glm(PROBLMUN1R ~EDAD + SEXO + ESTUDIOS + ESCIDEOL +
INGRESHOG + TAMUNI + CCAA + RELIGION, data = datos_train,family =
binomial(link="logit"))
```

```
summary(modelo_logit)

modelo_logit_final=glm(PROBLMUN1R ~variables, data = datos_train,family =
binomial(link="logit"))


# Predicciones en conjunto de prueba

probabilidades <- predict(modelo_logit, newdata = datos_test, type = "response")

predicciones <- ifelse(probabilidades > 0.5, levels(datos_train$PROBLMUN1R)[2],
levels(datos_train$PROBLMUN1R)[1])

predicciones <- factor(predicciones, levels = levels(datos_train$PROBLMUN1R))

confusion <- confusionMatrix(predicciones, datos_test$PROBLMUN1R)

print(confusion)


## ODS RATIO

# Instala y carga si no tienes broom

library(broom)


# Extraer los coeficientes y calcular OR e IC 95%

odds_ratios <- tidy(modelo_logit) %>%

  mutate(

    OR = exp(estimate),

    IC_low = exp(estimate - 1.96 * std.error),

    IC_high = exp(estimate + 1.96 * std.error)

  )


# Mostrar tabla ordenada por OR

print(odds_ratios[, c("term","estimate","std.error", "OR", "IC_low", "IC_high")])


# Filtrar solo las variables significativas (p < 0.05)

significativas <- odds_ratios %>%
```

```
  filter(p.value < 0.1) %>%
  select(term, estimate, std.error, OR,IC_low, IC_high) %>%
  arrange(desc(OR))

# Mostrar la tabla
print(significativas)

library(knitr)
kable(significativas)

## GRAFICO
# Datos del modelo (ajusta estos vectores a tus resultados reales)

variables <- c("RELIGION5", "INGRESHOG6", "CCAA14", "INGRESHOG5", "RELIGION6",
               "RELIGION4", "INGRESHOG3", "SEXOMujer", "CCAA12", "CCAA7", "CCAA4")
OR <- c(3.08, 2.70, 2.58, 1.99, 1.90, 1.78, 1.64, 1.37, 0.33, 0.32, 0.28)
IC_low <- c(1.27, 0.67, 0.74, 0.92, 0.85, 0.80, 0.87, 0.91, 0.15, 0.12, 0.09)
IC_high <- c(7.47, 10.93, 8.94, 4.30, 4.20, 3.94, 3.11, 2.06, 0.73, 0.84, 0.88)

# Crear dataframe
df_importancia <- data.frame(
  Variable = variables,
  OR = OR,
  IC_low = IC_low,
  IC_high = IC_high
)

# Ordenar por OR
```

```
df_importancia$Variable <- factor(df_importancia$Variable, levels =
df_importancia$Variable[order(df_importancia$OR)])

library(ggplot2)

# Gráfico
ggplot(df_importancia, aes(x = Variable, y = OR)) +
  geom_point(size = 3, color = "#0073C2FF") +
  geom_errorbar(aes(ymin = IC_low, ymax = IC_high), width = 0.2, color = "#0073C2FF") +
  coord_flip() +
  labs(title = "Importancia de las variables en el modelo logit",
       x = "Variable", y = "Odds Ratio (OR)") +
  theme_minimal()

##GRAFICO COEFICIENTES
# Supongamos que tienes un modelo logit llamado modelo_logit
coeficientes <- summary(modelo_logit)$coefficients

# Eliminar el intercepto
coeficientes <- coeficientes[-1, , drop = FALSE]

# Crear dataframe con valores absolutos
importancia_vars <- data.frame(
  Variable = rownames(coeficientes),
  Coeficiente = coeficientes[, "Estimate"],
  Importancia = abs(coeficientes[, "Estimate"])
)
```

```
# Ordenar por importancia

importancia_vars <- importancia_vars[order(importancia_vars$Importancia,
decreasing = TRUE), ]

importancia_vars$Variable <- factor(importancia_vars$Variable, levels =
importancia_vars$Variable)


# Gráfico de barras

library(ggplot2)

ggplot(importancia_vars, aes(x = Variable, y = Importancia)) +

  geom_bar(stat = "identity", fill = "#1F77B4") +

  coord_flip() +

  labs(title = "Importancia de las variables (coeficientes absolutos)",

       x = "Variable",

       y = "Importancia (|Coef|)") +

  theme_minimal()


##########################################################################
##########################################

                    ################# RANDOMFOREST #########################

##########################################################################
##########################################

library(randomForest)

library(caret)


### TABLA RESULTADOS

# Variables para almacenar resultados

resultados <- data.frame(mtry = integer(), nodesize = integer(), accuracy = numeric())


# Definir los valores que vamos a probar
```

```
mtry_vals <- c(2, 3, 4, 5, 6)
nodesize_vals <- c(1, 5, 10, 15, 20)

# Bucle para probar todas las combinaciones
for (m in mtry_vals) {
  for (n in nodesize_vals) {
    set.seed(13656549)# esta
    modelo <- randomForest(PROBLMUN1R ~ ., data = datos_train,
                           ntree = 500, mtry = m, nodesize = n)

    # Predicción sobre el conjunto de prueba
    predicciones <- predict(modelo, newdata = datos_test)

    # Calcular accuracy
    acc <- mean(predicciones == datos_test$PROBLMUN1R)

    # Guardar resultados
    resultados <- rbind(resultados, data.frame(mtry = m, nodesize = n, accuracy = acc))
  }
}

# Mostrar los resultados ordenados por accuracy
resultados <- resultados[order(-resultados$accuracy), ]
print(resultados)

set.seed(13656549)# esta
modelo_rf <- randomForest(PROBLMUN1R ~ ., data = datos_train, ntree = 500,
nodesize=5,mtry=4,importance = TRUE)
```

```
# Importancia de variables
importance(modelo_rf)
varImpPlot(modelo_rf)

# Predecir sobre los datos de prueba
predicciones <- predict(modelo_rf, newdata = datos_test)

# Evaluar con matriz de confusión
confusionMatrix(predicciones, datos_test$PROBLMUN1R)

##########################################################################
##########################################
      ################# REDES NEURONALES  #########################
##########################################################################
##########################################

library(nnet)
# Definir los valores que vamos a probar
nodesize_vals <- c(1:10)
resultados <- data.frame(mtry = integer(), nodesize = integer(), accuracy = numeric())

# Bucle para probar todas las combinaciones

 for (n in nodesize_vals) {
  set.seed(13656549)# esta
  modelo<- nnet(formula_nn, data = datos_train, size = n, maxit = 500, decay = 0.01)

  # Predicción sobre el conjunto de prueba
```

```
  pred_nn <- predict(modelo_nn, newdata = datos_test, type = "class")
  pred_nn <- factor(pred_nn, levels = levels(datos_test$PROBLMUN1R))

  # Calcular accuracy
  acc <- mean(pred_nn == datos_test$PROBLMUN1R)

  # Guardar resultados
  resultados <- rbind(resultados, data.frame(nodesize = n, accuracy = acc))
}



# Mostrar los resultados ordenados por accuracy
resultados <- resultados[order(-resultados$accuracy), ]
print(resultados)

# 3. Crear fórmula con todas las variables predictoras
formula_nn <- as.formula(paste("PROBLMUN1R ~", paste(setdiff(names(datos_train),
"PROBLMUN1R"), collapse = "+")))
set.seed(1234)# esta
# 4. Entrenar red neuronal (una capa oculta con 5 neuronas)
modelo_nn <- nnet(formula_nn, data = datos_train, size = 5, maxit = 500, decay = 0.01)
# 5. Predecir en test
pred_nn <- predict(modelo_nn, newdata = datos_test, type = "class")
pred_nn <- factor(pred_nn, levels = levels(datos_test$PROBLMUN1R))
# Medir accuracy
confusionMatrix(pred_nn, test_df$PROBLMUN1R)

boxplot(pred_nn, datos_test$PROBLMUN1R)
```

```
## GRAFICOS
library(NeuralNetTools)
garson(modelo_nn)

# Obtener importancia de variables con olden
imp_data <- olden(modelo_nn, bar_plot = FALSE)

# Convertir a data.frame y ordenar
imp_df <- data.frame(Variable = rownames(imp_data), Importance = imp_data[, 1])
imp_df <- imp_df[order(imp_df$Importance, decreasing = TRUE), ]
imp_df <- imp_df %>%
  subset(imp_df$Importance>20| imp_df$Importance< -20)
# Graficar con ggplot2 (horizontal para leer bien los nombres)
ggplot(imp_df, aes(x = reorder(Variable, Importance), y = Importance)) +
 geom_col(fill = "skyblue") +
 coord_flip() +  # pone las variables en el eje Y
 labs(
  title = "Importancia de las variables en el modelo nnet",
  x = "Variable", y = "Importancia"
 ) +
 theme_minimal() +
 theme(axis.text.y = element_text(size = 9))  # ajusta el tamaño de los nombres
```

```
##########################################################################
###################
#################### COMPARACION DE MODELOS
########################################
```

```
#######################################################################
################

# Accuracy de ambos modelos (usa tus valores reales si cambian)
accuracy_rf <-  0.7421
accuracy_logit <-  0.6953
accuracy_NNET <- 0.7344
s_rf=0.2500;s_logit=0.2955;s_nnet=0.4545
e_rf=0.97619;e_logit=0.9048;e_nnet=0.8810
df_accuracy <- data.frame(
  Modelo = c("Random Forest", "Regrsión Logit", "Redes Neuronales"),
  Accuracy = c(accuracy_rf, accuracy_logit, accuracy_NNET),
  Sensibilidad=c(s_rf,s_logit,s_nnet),
  Especificidad =c(e_rf,e_logit,e_nnet)
)
library(kableExtra)
kable(df_accuracy)

# Crear data frame para graficar
df_accuracy <- data.frame(
  Modelo = c("Random Forest", "Regresión Logit", "Redes Neuronales"),
  Accuracy = c(accuracy_rf, accuracy_logit, accuracy_NNET)
)

library(ggplot2)
library(caret)
# Gráfico de barras comparativo
ggplot(df_accuracy, aes(x = Modelo, y = Accuracy, fill = Modelo)) +
```

```
  geom_col(width = 0.6) +
  geom_text(aes(label = round(Accuracy, 3)), vjust = -0.5, size = 5) +
  ylim(0, 1) +
  labs(title = "Comparación de precisión entre modelos",
       y = "Precisión (Accuracy)", x = "") +
  scale_fill_manual(values = c("#1f77b4", "#ff7f0e", "pink")) +
  theme_minimal(base_size = 14)
##########################################################################
##########################################
################# ANALISIS DESCRIPTIVO  #########################
##########################################################################
##########################################


library(skimr)
skim(datos_train)


#VARIABLES NUMERICA
library(ggplot2)


num_vars <- datos_limpios %>% select(where(is.numeric))


# Histograma por variable
for (var in names(num_vars)) {
  print(
    ggplot(datos_limpios, aes_string(x = var)) +
```

```
    geom_histogram(bins = 30, fill = "steelblue", color = "white") +
    labs(title = paste("Distribución de", var))
  )
}

# Estadísticos
summary(num_vars)

# VARIABLES CATEGORICAS
library(dplyr)
library(knitr)
library(kableExtra)
# Todas las variables categóricas
cat_vars <- datos_filtrados %>% select(where(is.factor))

# Creamos tabla bonita para cada variable
for (var in names(cat_vars)) {

  tabla <- cat_vars %>%
    count(!!sym(var)) %>%
    mutate(Porcentaje = round(100 * n / sum(n), 2)) %>%
    rename(Categoría = 1, Frecuencia = n)
```

```
  cat("\n\n")
  cat(paste("### Variable:", var, "\n"))

  # Mostramos la tabla bonita
  print(
    tabla %>%
      kbl(caption = paste("Distribución de la variable", var),
          align = "lcc", format = "html") %>%
      kable_styling(full_width = FALSE, bootstrap_options = c("striped", "hover",
"condensed"))
  )
}

# Gráfico para PROBLMUN2R
ggplot(datos_filtrados, aes(x = PROBLMUN2R)) +
  geom_bar(fill = "#0073C2FF") +
  theme_minimal() +
  labs(title = "Distribución de PROBLMUN2R",
       x = "Categorías",
       y = "Frecuencia") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

# Gráfico para PROBLMUN3R
ggplot(datos_filtrados, aes(x = PROBLMUN3R)) +
```

```
geom_bar(fill = "#0073C2FF") +

theme_minimal() +

labs(title = "Distribución de PROBLMUN3R",

    x = "Categorías",

    y = "Frecuencia") +

theme(axis.text.x = element_text(angle = 45, hjust = 1))
```